



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校	待填写
参赛队号	待填写
队员姓名	1. 待填写
	2. 待填写
	3. 待填写

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

**题 目： 基于公共时间轴与掩码门控融合的多模态情感预测
及证据追踪**

摘 要：

复杂场景下的情感预测面临三模态时间尺度不一致、局部信息缺失和决策依据难以追溯的问题。本文以赛题提供的文本、语音、视觉数据为基础，建立“**特征提取与时间对齐—鲁棒预测—证据解释**”的统一建模流程，同时输出情感极性和连续情感强度。

针对问题一，考虑原始视频、语音和转写文本的采样机制不同，建立 **50 个半开公共时间窗与显式缺失掩码**，按观测区间重叠时长完成跨模态映射，并分别提取 768 维文本、74 维语音和 35 维视觉特征。附件 1 的 100 条样本均完成时间结构核验；语音、视觉和文本的有效窗率分别为 **99.00%、99.80% 和 58.68%**。文本缺少人工词级时间真值，因此其定位仅作为声学约束下的弱或半强对齐。

针对问题二，为应对连续时间窗内的局部模态缺失，构建**三路双向 GRU、掩码时间注意力和样本级模态门控**组成的双任务融合模型，并保持训练、验证和专项推理的输入接口一致。附件 2 验证集上，最终模型的 Accuracy 和 Macro-F1 分别为 **0.637363 和 0.601580**，强度预测的 MAE 和 Pearson 相关系数分别为 **0.612262 和 0.629628**；四项指标均优于固定对齐基线。两者文本特征版本不同，上述差异属于完整系统比较，不单独归因于网络结构。进一步分析缺失模态、遮挡位置和时长，并对无标签附件 3 输出预测结果，不以其计算监督指标。

针对问题三，围绕“哪种模态、哪个片段影响当前判断”，结合**模态消融、时间窗反事实遮挡与原始视频关键帧回溯**生成可复核的解释。附件 2 验证集 128 条样本中，最高注意力窗口遮挡后的平均置信度下降为 **0.010919**，随机窗口为 **0.001215**；附件 4 的 20 条无标签样本均输出极性、强度和局部证据。该解释刻画模型行为，不等同于人类情感的因果机制。

关键词： 多模态情感预测 公共时间轴 局部模态缺失 掩码门控 可解释性

目录

1	问题背景与问题重述	5
1.1	问题背景分析	5
1.2	数据介绍与建模目标	5
1.2.1	数据介绍	5
1.2.2	建模目标	6
1.3	问题重述	6
1.4	解题流程	7
2	建模假设、符号与评价体系	9
2.1	数据与任务假设	9
2.2	核心变量与符号	9
2.3	分类、回归与对齐评价指标	10
3	问题一：三模态特征构建与公共时间轴对齐	12
3.1	问题一分析	12
3.2	模型建立：数据组织与公共时间轴	12
3.2.1	50 窗公共时间轴与掩码定义	16
3.3	模型求解：三模态特征提取	16
3.3.1	文本编码与声学约束定位	16
3.3.2	语音窗口特征提取	16
3.3.3	视觉关键帧特征提取	17
3.4	对齐结果与典型样本核验	17
3.4.1	时间结构与模态覆盖率核验	17
3.4.2	典型样本的跨模态时间对应	18
3.4.3	缺少人工词级真值的评价边界	19
4	问题二：局部模态缺失下的鲁棒情感预测	20
4.1	问题二分析	20
4.2	模型建立：掩码感知的时序融合	20
4.2.1	固定基线与模型设计依据	20
4.2.2	训练集统计量与掩码归一化	20

4.2.3	三路双向 GRU 时序编码	21
4.2.4	有效时间窗注意力	21
4.2.5	样本级动态模态门控	21
4.2.6	融合表示与分类回归双输出	22
4.2.7	网络结构与参数规模	22
4.3	模型训练与实验协议	23
4.3.1	联合目标与训练流程	23
4.3.2	统一输入接口与数据用途	24
4.3.3	监督样本划分与类别比例	24
4.3.4	训练与推理接口一致性审计	25
4.3.5	分类回归联合选择准则	26
4.4	模型求解与验证集性能	26
4.4.1	候选模型的验证集筛选	26
4.4.2	极性分类与强度回归结果	28
4.4.3	分类混淆与强度误差诊断	29
4.5	局部缺失实验与附件 3 推理	30
4.5.1	缺失类型、位置与时长敏感性	30
4.5.2	逐模态窗口遮挡响应	32
4.5.3	附件 3 无标签样本预测	33
4.6	独立测试与误差复核	34
4.6.1	附件 2 测试集的独立复核	34
4.6.2	验证集收益与测试集波动	35
4.6.3	单次划分的统计推断边界	35
5	问题三：模态与时间窗贡献的可解释预测	37
5.1	问题三分析	37
5.2	解释模型建立与证据量化	37
5.2.1	沿用模型与解释训练协议	37
5.2.2	模态作用程度的消融估计	38
5.2.3	关键时间窗的反事实遮挡	38
5.3	解释结果验证与典型样本	38
5.4	附件 4 预测与证据追踪	40
5.4.1	极性与强度预测分布	40
5.4.2	代表样本的预测核验	41

5.4.3	证据字段与原始媒体对应	42
5.4.4	视频关键帧与文本片段追踪	42
5.4.5	解释结果的可复核性与局限	42
6	模型评价与适用边界	44
6.1	输入一致性与局部缺失鲁棒性	44
6.1.1	局部缺失机制与掩码响应	44
6.2	预测收益与计算代价	44
6.2.1	参数量、运算量与候选准入	44
6.3	误差来源与可复现性	47
6.3.1	跨场景适用条件	47
6.3.2	可复现实验与证据留存	48
6.3.3	最终模型准入条件与风险边界	48
7	结论与展望	50
	参考文献	51
	附录	52
A	数据字段与交付文件	52
A.1	输入特征、掩码与标签字段	52
A.2	预测、解释与论文交付文件	52
B	核验规则与关键算法	53
B.1	公共时间轴核验算法	53
B.2	掩码门控模型前向算法	53
B.3	模态与时间窗证据生成算法	54
B.4	结果一致性审计规则	54
C	模型配置与训练记录	55
C.1	候选模型验证记录	55
C.2	软件环境与版本	56
D	附件 4 预测与证据记录	56
D.1	局部证据字段释义	57
E	复现流程与提交前核对	57
E.1	特征构建、训练与验证命令	57
E.2	交付文件一致性核对	58
E.3	结果解释与适用范围声明	58

1 问题背景与问题重述

1.1 问题背景分析

情感是人机交互中的重要信息。真实视频里的态度与情绪通常由语言内容、声音的节奏和音高、面部表情及动作共同表达；单看转写文本，可能遗漏语气变化，单看声音或画面，也可能失去语义背景。多模态情感计算研究因此强调联合分析多种信号及其交互 [1, 2]。中文研究进一步从叙述式与交互式任务梳理多模态情感分析的发展脉络，并指出交互建模是影响识别效果的关键问题 [3]；针对视频场景，已有综述将模态融合、时间对齐和模态噪声列为需要同时处理的核心环节 [4]。本题以 CMU-MOSEI 英文多模态数据为基础，要求同时利用文本、语音和视觉信息预测情感极性与强度。

将三种信息放入同一模型并非简单拼接。文本按词或 token 组织，语音按声学帧采样，视觉按视频帧采样；即使特征数组长度相同，相同下标也未必对应同一时刻。非对齐多模态序列的建模已有专门研究 [5]。真实片段还可能因噪声、遮挡或转写失败而出现局部信息缺失。若把缺失位置当作有效零值，或始终给予三个模态固定权重，预测就可能依赖错误证据。与此同时，模型仅给出类别和强度还不足以复核判断：需要说明当前样本主要参考了哪种模态、哪些时间片段，并能回到原始媒体查看。

由此形成三个相互衔接的建模难点：异步特征如何在真实时间上对应，局部缺失时如何稳定预测，以及预测依据如何量化并追溯。第一项决定输入是否可信，第二项决定预测是否能应对复杂场景，第三项决定结果是否可审阅。

1.2 数据介绍与建模目标

1.2.1 数据介绍

赛题提供四组用途不同的材料，见表 1.1。

表 1.1 赛题附件的数据内容与建模用途

附件	规模	主要内容	本文用途
1	100 条	原始视频、英文转写和极性/强度标注	问题一的特征提取、时间对齐与回看核验
2	4850 条	已处理的三模态特征及标签，按训练、验证、测试划分；含对齐与非对齐版本	问题二、三的监督训练、验证选模和独立复核
3	30 条	存在局部模态缺失的无标签特征样本	问题二的专项推理与输出记录
4	20 条	三模态完整的无标签特征及原始视频	问题三的预测、解释与证据回溯

附件 1 的 100 条原始英文视频分布在 37 个以 video_id 命名的文件夹中，视频片段由 video_id 与 clip_id 共同标识，时长约为 2.257–29.288 秒；配套表格给出转写文本、三类情感极性和 $[-3, 3]$ 范围的连续强度，其中 0 只属于中性。附件 1 用于从原始媒体建立和核验特征、时间轴与样本对应关系。

附件 2 的特征文件提供 aligned_50.pkl 与 unaligned_50.pkl 两套时序组织形式，训练、验证和专项推理必须保持特征版本与输入接口一致。附件 3 和附件 4 没有真实情感标签，只能报告预测及证据，不能据此计算 Accuracy、F1 或 MAE。附件 1 与附件 2 是不同的样本集合：前者检验从原始媒体建立可审计特征的能力，后者承担问题二、三的模型学习；不能把附件 1 的 100 条视频误写为后续模型的训练集。

1.2.2 建模目标

本文以情感极性、连续强度和可追溯证据为最终输出，依次实现三个目标。首先，对附件 1 建立样本 ID、模态特征、有效时间位置与原始媒体之间的对应关系，使跨模态对齐可以核验。其次，利用附件 2 的训练集学习在局部模态缺失下仍可使用的极性分类和强度回归模型，并以验证集进行选择；缺失类型、位置、时长的影响应分别检验。最后，为每条待解释样本提供主要参考模态、模态作用程度和关键时间窗，将证据映射回文本片段、语音时段或视觉关键帧。分类、回归与解释的具体评价口径在第 2 节给出。

1.3 问题重述

根据题面，本文需要完成以下三个相互衔接的问题。

问题一：多模态特征提取与时序对齐。

以附件 1 的 100 条原始视频及标注为输入，定义文本、语音、视觉特征和跨模态时间对应规则。输出特征文件应覆盖全部样本，记录有效长度、填充位置及原始素材索引；还需用典型样本展示对齐效果，说明工具、参数和处理日志。

问题二：局部模态缺失下的情感预测。

利用附件 2 的带标签特征学习模型，在文本、语音或视觉的部分连续时段不可用时，同时预测情感极性和连续情感强度。分别分析缺失模态、位置和时长对预测性能的影响，并对无标签附件 3 输出预测文件。

问题三：可解释的情感预测与证据定位。

在附件 2 上建立和验证可解释模型，对附件 4 输出极性、强度、主要参考模态及其作用程度。定位对判断重要的局部片段，使文本、语音和视觉证据可以对应原始材料，并提交预测与解释文件。

问题二与问题三均只用附件 2 训练集学习参数、用验证集选择模型；附件 3 和附件 4 仅用于各自的最终专项推理。极性任务以 Accuracy 和 F1 评价，强度任务以 MAE 和 Pearson 相关系数评价。

1.4 解题流程

本文采用图 1.1 所示的三问解题路线。问题一从附件 1 原始媒体提取三模态特征，以实际媒体时长建立公共时间窗，记录每个窗口的有效掩码和原始位置；问题二使用附件 2 的同版特征及训练集统计量，建立掩码感知的时序融合与双任务输出，再在验证集比较指标并开展局部遮挡实验；问题三沿用经过选模的统一输入和模型，结合模态消融、窗口遮挡与原始视频回看形成解释证据。附件 3、附件 4 在流程末端分别进入对应专项推理，不参与训练或反向选模。




图 1.1 三个问题的建模流程及数据关系

图中的路线概括了各问题共享的时间索引、掩码和证据规则，并不表示附件 1 产生的 100 条特征被直接用于附件 2 的监督训练。各阶段保留样本 ID、特征版本、有效窗口和输出文件之间的对应记录，使模型指标与关键证据都能追溯到其输入来源。

2 建模假设、符号与评价体系

2.1 数据与任务假设

为保证问题可解并保留可审计性，作如下假设：

1. 每条样本可用一个实际解码得到的媒体时长 T_n 描述，公共窗口均使用半开区间，因此相邻窗口不会重复计算边界点。
2. 音频和视觉的局部观测在其有效时间范围内代表对应窗口的局部状态；媒体末端无真实观测时置为缺失，不使用容器标称长度伪造特征。
3. 文本没有人工词级起止时间戳，因此文本定位只作为弱或半强时间约束；CTC 后验、语音活动候选和结构合法性不能替代人工 gold timestamp。
4. 训练集统计量只能由训练划分估计，验证集、附件 3 和附件 4 不得反向参与均值、方差、阈值或模型选择。
5. 情感极性和连续强度共享一定的潜在情绪表示，但允许通过两个不同输出头保留任务差异。
6. 模态缺失可以通过掩码被观测，缺失模式本身可能携带信息，因此不对掩码进行随机删除或隐式填零替代。

2.2 核心变量与符号

下文以样本 n 、公共窗口 k 和模态 q 为基本索引。表 2.1 汇总时间轴、有效掩码、模型权重与两项预测任务所用的主要符号；同一符号在各问题中保持相同含义。

表 2.1 主要符号及含义

符号	含义
n	样本索引, $n = 1, \dots, N$
T_n	第 n 条样本的实际媒体时长
K	公共时间窗数, 本文固定为 $K = 50$
$I_{n,k}$	第 n 条样本的第 k 个半开时间窗
$m_{n,k}^{(q)}$	模态 q 在窗口 k 是否有效的掩码
$z_{n,k}^{(q)}$	模态 q 在窗口 k 的归一化特征
$h_{n,k}^{(q)}$	模态 q 的时序编码表示
$\alpha_{n,k}^{(q)}$	模态 q 内部第 k 个时间窗的注意力权重
$\beta_n^{(q)}$	样本级模态门控权重
$\hat{y}_n^{(c)}, \hat{y}_n^{(r)}$	极性预测和强度预测
$\Delta_{n,k}^{(q)}$	遮挡一个模态窗口后, 目标类别置信度的变化量

2.3 分类、回归与对齐评价指标

分类任务使用 Accuracy 和 Macro-F1。令 y_i 为真实类别、 $\hat{y}_i$ 为预测类别, 则

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(y_i = \hat{y}_i). \quad (2.1)$$

对类别 c , 精确率、召回率和 F1 分数分别为

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad (2.2)$$

$$R_c = \frac{TP_c}{TP_c + FN_c}, \quad (2.3)$$

$$F1_c = \frac{2P_c R_c}{P_c + R_c}. \quad (2.4)$$

Macro-F1 为三个类别 F1 的算术平均。类别不均衡时, 分层检查精确率和召回率比只看总体正确率更有辨识力 [6, 7]。本文将 Macro-F1 作为主分类选择指标, 同时报告 Accuracy。

连续情感强度采用平均绝对误差和 Pearson 相关系数:

$$\text{MAE} = \frac{1}{N} \sum_i |y_i^{(r)} - \hat{y}_i^{(r)}|. \quad (2.5)$$

$$\rho = \frac{\sum_i (y_i^{(r)} - \bar{y})(\hat{y}_i^{(r)} - \bar{\hat{y}})}{\sqrt{\sum_i (y_i^{(r)} - \bar{y})^2} \sqrt{\sum_i (\hat{y}_i^{(r)} - \bar{\hat{y}})^2}}. \quad (2.6)$$

对于对齐质量，本文报告覆盖率、时间窗起点为零率、连续率、终点一致率、词段越界率、正时长率、单调率和无重叠率。解释质量不写成因果准确率，而使用最大注意力窗口与随机窗口遮挡后的置信度下降差值

$$\text{TopRandom} = \bar{\Delta}_{\text{top}} - \bar{\Delta}_{\text{random}}. \quad (2.7)$$

3 问题一：三模态特征构建与公共时间轴对齐

3.1 问题一分析

问题一要求从附件 1 原始视频建立可追溯的三模态特征，而不是仅使三个特征矩阵具有相同长度。文本转写缺少人工词级时间戳，语音和视觉的采样率又不同，因此必须先确定真实媒体时长和公共时间索引，再记录每个模态在各窗口是否存在有效观测。求解分为数据与特征构建、公共时间轴映射、全量结构核验和典型样本回看四步；词级定位没有人工真值，只能报告结构合法性与声学约束质量。

图 3.1 概括了问题一的输入、处理与核验路径。三模态特征共同映射到实际媒体时长确定的 50 个窗口；末端无观测或局部无效的位置由掩码标记，不用填充值冒充有效证据。




图 3.1 问题一的特征提取、时间对齐与核验流程

3.2 模型建立：数据组织与公共时间轴

本题提供四组用途不同的附件。问题一以附件 1 原始视频及其转写、标签为输入，保留每条样本的原始 ID、文本、音频、视频和标签关系。附件 2 用于后续训练、验证和独立测试复核；附件 3 用于缺失模态专项推理，没有真实标签；附件 4 用于最终预测、证据和视频关键帧回溯，同样没有监督标签。本文所有模型选择只使用附件 2 训练与验证划分，不使用附件 3 或附件 4 的伪标签。

附件 1 的 100 条样本均映射至 50 个公共时间窗；文本、语音、视觉特征维度依次为 768、74 和 35。文本特征来自固定版本的 `distilbert-base-uncased`，具体做法是取最后四层隐状态逐元素均值，并对无效 token 置零。语音特征以 16 kHz 单声道解码结果为输入，视觉特征以视频窗口中心附近的真实帧为输入。

表 3.1 三模态输入与时间定位规则

模态	维度	特征构成	时间定位与缺失规则
文本	768	DistilBERT 最后四层均值	由题目转写、CTC 路径和语音活动候选形成弱或半强定位；低置信或冲突样本屏蔽
语音	74	MFCC、Chroma、谱统计、基频、过零率和 RMS	16 kHz 单声道音频分帧，按窗口重叠时长加权；无真实解码覆盖则置掩码 0
视觉	35	人脸、亮度/颜色、纹理、梯度、运动与对称性	每窗取最接近中心的真实视频帧；无法解码的窗口置掩码 0

问题一生成的特征文件采用 Pickle 字典保存，顶层键为 `all` 和 `metadata`。其中 `all` 按样本第一维保存 `id`、`raw_text`、`text`、`audio`、`vision`、三类掩码、时间边界、标签和来源文件；三类特征形状分别为 (100, 50, 768)、(100, 50, 74) 和 (100, 50, 35)。`metadata` 保存版本号、特征维度、提取器、对齐规则和软件版本。读取时先执行 `obj=pickle.load(open(path,'rb'))`，再以 `obj['all']['text'][j]`、`obj['all']['audio'][j]` 和 `obj['all']['vision'][j]` 读取第 j 条样本；第 k 个窗口的时间边界、特征和掩码使用相同的 (j, k) 索引。`feature_manifest.csv` 同步记录每个样本的来源文件、原始时长、有效时长、维度和校验哈希，保证表 3.2 与输出文件一一对应。

表 3.2 附件 1 全部 100 条样本的三模态特征汇总

样本编号	模态类型	原始有效时长 (s)	特征维度	对齐粒度
-3g5yACwYnA\$_13	text/audio/vision	5.513997	768/74/35	50 窗（各模态）
-3g5yACwYnA\$_3	text/audio/vision	14.388997	768/74/35	50 窗（各模态）
-3g5yACwYnA\$_2	text/audio/vision	9.394010	768/74/35	50 窗（各模态）
-3g5yACwYnA\$_9	text/audio/vision	8.816992	768/74/35	50 窗（各模态）
-3nNcZdedvU\$_5	text/audio/vision	7.867969	768/74/35	50 窗（各模态）
-HwX2H8Z4hY\$_2	text/audio/vision	3.982031	768/74/35	50 窗（各模态）
-HwX2H8Z4hY\$_5	text/audio/vision	5.652995	768/74/35	50 窗（各模态）
-HwX2H8Z4hY\$_6	text/audio/vision	3.358008	768/74/35	50 窗（各模态）
-HwX2H8Z4hY\$_9	text/audio/vision	7.733984	768/74/35	50 窗（各模态）
-NFrJFQijFE\$_1	text/audio/vision	5.746000	768/74/35	50 窗（各模态）
-NFrJFQijFE\$_2	text/audio/vision	6.856000	768/74/35	50 窗（各模态）
-THoVjtlkeU\$_12	text/audio/vision	14.896029	768/74/35	50 窗（各模态）
-THoVjtlkeU\$_2	text/audio/vision	4.291992	768/74/35	50 窗（各模态）
-THoVjtlkeU\$_6	text/audio/vision	8.097005	768/74/35	50 窗（各模态）
-UuX1xuuiE\$_1	text/audio/vision	10.350000	768/74/35	50 窗（各模态）

样本编号	模态类型	原始有效时长 (s)	特征维度	对齐粒度
-UuX1xuaiiES_\$0	text/audio/vision	3.633333	768/74/35	50 窗 (各模态)
-UuX1xuaiiES_\$3	text/audio/vision	4.130013	768/74/35	50 窗 (各模态)
-UuX1xuaiiES_\$6	text/audio/vision	8.113997	768/74/35	50 窗 (各模态)
-a55Q6RWvTA\$_\$3	text/audio/vision	22.153971	768/74/35	50 窗 (各模态)
-aNfi7CP8vM\$_\$7	text/audio/vision	8.694987	768/74/35	50 窗 (各模态)
-aqamKhZ1Ec\$_\$0	text/audio/vision	10.966667	768/74/35	50 窗 (各模态)
-dxftGcXJoc\$_\$1	text/audio/vision	16.161003	768/74/35	50 窗 (各模态)
-dxftGcXJoc\$_\$0	text/audio/vision	20.500000	768/74/35	50 窗 (各模态)
-dxftGcXJoc\$_\$2	text/audio/vision	16.697982	768/74/35	50 窗 (各模态)
-dxftGcXJoc\$_\$6	text/audio/vision	12.735026	768/74/35	50 窗 (各模态)
-egA8-b7-3M\$_\$26	text/audio/vision	6.030990	768/74/35	50 窗 (各模态)
-egA8-b7-3M\$_\$17	text/audio/vision	7.271029	768/74/35	50 窗 (各模态)
-egA8-b7-3M\$_\$18	text/audio/vision	8.386003	768/74/35	50 窗 (各模态)
-egA8-b7-3M\$_\$16	text/audio/vision	5.538021	768/74/35	50 窗 (各模态)
-egA8-b7-3M\$_\$13	text/audio/vision	4.183984	768/74/35	50 窗 (各模态)
-egA8-b7-3M\$_\$1	text/audio/vision	10.266016	768/74/35	50 窗 (各模态)
-egA8-b7-3M\$_\$6	text/audio/vision	6.264974	768/74/35	50 窗 (各模态)
-egA8-b7-3M\$_\$9	text/audio/vision	5.089974	768/74/35	50 窗 (各模态)
-egA8-b7-3M\$_\$20	text/audio/vision	6.644987	768/74/35	50 窗 (各模态)
-iRBcNs9oI8\$_\$3	text/audio/vision	5.621000	768/74/35	50 窗 (各模态)
-iRBcNs9oI8\$_\$7	text/audio/vision	4.104000	768/74/35	50 窗 (各模态)
-iRBcNs9oI8\$_\$6	text/audio/vision	2.903000	768/74/35	50 窗 (各模态)
-iRBcNs9oI8\$_\$9	text/audio/vision	3.416000	768/74/35	50 窗 (各模态)
-iRBcNs9oI8\$_\$8	text/audio/vision	8.093000	768/74/35	50 窗 (各模态)
-IzEya4AM_4\$_\$5	text/audio/vision	7.675000	768/74/35	50 窗 (各模态)
-IzEya4AM_4\$_\$6	text/audio/vision	14.791992	768/74/35	50 窗 (各模态)
-mJ2ud6oKI8\$_\$1	text/audio/vision	6.103000	768/74/35	50 窗 (各模态)
-mJ2ud6oKI8\$_\$2	text/audio/vision	5.731000	768/74/35	50 窗 (各模态)
-mJ2ud6oKI8\$_\$6	text/audio/vision	2.257000	768/74/35	50 窗 (各模态)
-mJ2ud6oKI8\$_\$9	text/audio/vision	7.033000	768/74/35	50 窗 (各模态)
-mJ2ud6oKI8\$_\$8	text/audio/vision	4.192000	768/74/35	50 窗 (各模态)
-mqbVkbCndg\$_\$0	text/audio/vision	6.466667	768/74/35	50 窗 (各模态)
-t217m2on-s\$_\$2	text/audio/vision	5.686003	768/74/35	50 窗 (各模态)
-t217m2on-s\$_\$7	text/audio/vision	17.183008	768/74/35	50 窗 (各模态)
-tANM6ETI_M\$_\$3	text/audio/vision	6.758008	768/74/35	50 窗 (各模态)
-tPCytz4rww\$_\$11	text/audio/vision	5.466992	768/74/35	50 窗 (各模态)
-tPCytz4rww\$_\$10	text/audio/vision	4.788997	768/74/35	50 窗 (各模态)
-tPCytz4rww\$_\$12	text/audio/vision	11.863997	768/74/35	50 窗 (各模态)
-tPCytz4rww\$_\$16	text/audio/vision	7.205990	768/74/35	50 窗 (各模态)
-tPCytz4rww\$_\$18	text/audio/vision	6.644987	768/74/35	50 窗 (各模态)
-vxjVxOeScU\$_\$4	text/audio/vision	9.127018	768/74/35	50 窗 (各模态)
-wMB_hJL-3o\$_\$7	text/audio/vision	6.044010	768/74/35	50 窗 (各模态)
-wny00Az3g8\$_\$1	text/audio/vision	6.844010	768/74/35	50 窗 (各模态)
-wny00Az3g8\$_\$0	text/audio/vision	3.333333	768/74/35	50 窗 (各模态)
-wny00Az3g8\$_\$3	text/audio/vision	6.146029	768/74/35	50 窗 (各模态)

样本编号	模态类型	原始有效时长 (s)	特征维度	对齐粒度
-wny00Az3g8\$_\$2	text/audio/vision	6.686979	768/74/35	50 窗 (各模态)
-wny00Az3g8\$_\$5	text/audio/vision	6.911979	768/74/35	50 窗 (各模态)
-wny00Az3g8\$_\$7	text/audio/vision	8.067969	768/74/35	50 窗 (各模态)
-wny00Az3g8\$_\$9	text/audio/vision	6.213021	768/74/35	50 窗 (各模态)
-571d8cVauQ\$_\$0	text/audio/vision	5.066667	768/74/35	50 窗 (各模态)
-571d8cVauQ\$_\$5	text/audio/vision	15.272982	768/74/35	50 窗 (各模态)
-I_e4mIh0yE\$_\$1	text/audio/vision	7.622005	768/74/35	50 窗 (各模态)
-I_e4mIh0yE\$_\$3	text/audio/vision	9.163021	768/74/35	50 窗 (各模态)
-UacrmKiTn4\$_\$10	text/audio/vision	7.361979	768/74/35	50 窗 (各模态)
-UacrmKiTn4\$_\$4	text/audio/vision	4.741016	768/74/35	50 窗 (各模态)
-hnBHBn8p5A\$_\$7	text/audio/vision	7.372000	768/74/35	50 窗 (各模态)
-hnBHBn8p5A\$_\$6	text/audio/vision	6.401000	768/74/35	50 窗 (各模态)
-qDkUB0GgYY\$_\$6	text/audio/vision	4.677995	768/74/35	50 窗 (各模态)
-uywlfYOS8\$_\$4	text/audio/vision	6.044987	768/74/35	50 窗 (各模态)
-6rXp3zJ3kc\$_\$8	text/audio/vision	12.805013	768/74/35	50 窗 (各模态)
-9y-fZ3swSY\$_\$0	text/audio/vision	6.833333	768/74/35	50 窗 (各模态)
-9y-fZ3swSY\$_\$4	text/audio/vision	2.821029	768/74/35	50 窗 (各模态)
-9y-fZ3swSY\$_\$8	text/audio/vision	4.988997	768/74/35	50 窗 (各模态)
-AUZQgSxyPQ\$_\$2	text/audio/vision	22.511003	768/74/35	50 窗 (各模态)
-HeZS2-Prhc\$_\$2	text/audio/vision	8.261979	768/74/35	50 窗 (各模态)
-MeTTeMJBnc\$_\$0	text/audio/vision	9.300000	768/74/35	50 窗 (各模态)
-MeTTeMJBnc\$_\$13	text/audio/vision	5.430013	768/74/35	50 窗 (各模态)
-MeTTeMJBnc\$_\$7	text/audio/vision	10.516992	768/74/35	50 窗 (各模态)
-RfYyzHpjk4\$_\$11	text/audio/vision	5.238997	768/74/35	50 窗 (各模态)
-RfYyzHpjk4\$_\$8	text/audio/vision	4.588997	768/74/35	50 窗 (各模态)
-RfYyzHpjk4\$_\$2	text/audio/vision	5.516016	768/74/35	50 窗 (各模态)
-UUCSKoHeMA\$_\$0	text/audio/vision	7.800000	768/74/35	50 窗 (各模态)
-ri04Z7vwnc\$_\$0	text/audio/vision	2.807000	768/74/35	50 窗 (各模态)
-ri04Z7vwnc\$_\$2	text/audio/vision	6.027000	768/74/35	50 窗 (各模态)
-ri04Z7vwnc\$_\$5	text/audio/vision	3.545000	768/74/35	50 窗 (各模态)
-s9qJ7ATP7w\$_\$1	text/audio/vision	4.791992	768/74/35	50 窗 (各模态)
-s9qJ7ATP7w\$_\$0	text/audio/vision	6.800000	768/74/35	50 窗 (各模态)
-s9qJ7ATP7w\$_\$5	text/audio/vision	8.561003	768/74/35	50 窗 (各模态)
-s9qJ7ATP7w\$_\$4	text/audio/vision	4.427018	768/74/35	50 窗 (各模态)
-s9qJ7ATP7w\$_\$7	text/audio/vision	6.966016	768/74/35	50 窗 (各模态)
-s9qJ7ATP7w\$_\$6	text/audio/vision	2.475000	768/74/35	50 窗 (各模态)
-s9qJ7ATP7w\$_\$8	text/audio/vision	3.294987	768/74/35	50 窗 (各模态)
-yRb-Jum7EQ\$_\$1	text/audio/vision	29.288021	768/74/35	50 窗 (各模态)
-yRb-Jum7EQ\$_\$5	text/audio/vision	13.169010	768/74/35	50 窗 (各模态)
-yRb-Jum7EQ\$_\$6	text/audio/vision	11.241995	768/74/35	50 窗 (各模态)

3.2.1 50 窗公共时间轴与掩码定义

令第 n 条样本实际媒体时长为 T_n ，固定划分 $K = 50$ 个半开公共窗口：

$$I_{n,k} = \left[\frac{kT_n}{K}, \frac{(k+1)T_n}{K} \right), \quad k = 0, 1, \dots, K-1. \quad (3.1)$$

半开区间具有两个优点：一方面首窗从 0 开始，末窗终点严格等于媒体时长；另一方面相邻窗口边界不重复。对于模态 q 的第 i 个局部观测，记其覆盖区间为 $J_{n,i}^{(q)}$ ，特征为 $x_{n,i}^{(q)}$ ，则窗口级特征定义为

$$z_{n,k}^{(q)} = \frac{\sum_i |I_{n,k} \cap J_{n,i}^{(q)}| x_{n,i}^{(q)}}{\sum_i |I_{n,k} \cap J_{n,i}^{(q)}|}, \quad \text{when } \sum_i |I_{n,k} \cap J_{n,i}^{(q)}| > 0. \quad (3.2)$$

若分母为零，则令 $z_{n,k}^{(q)} = 0$ ，同时定义 $m_{n,k}^{(q)} = 0$ 。如果窗口内有至少一个有效观测，则 $m_{n,k}^{(q)} = 1$ 。在后续网络中，特征值和掩码始终成对传递，不允许仅凭数值判断窗口是否缺失。

3.3 模型求解：三模态特征提取

3.3.1 文本编码与声学约束定位

题目提供了两种文本接口：预计算的 `text` 和 `token` 形式的 `text_bert`。分布式词表示与上下文预训练编码为文本序列建模提供了基础 [8, 9, 10]；本文使用的具体编码器为 DistilBERT[11]。为了避免训练和专项测试接口不一致，最终路线固定采用 `text_bert`。对于每个窗口的 `token` 集合 $S_{n,k}$ ，DistilBERT 产生最后四层隐状态 $H^{(1)}, \dots, H^{(4)}$ ，文本表示为

$$z_{n,k}^{(t)} = \frac{1}{|S_{n,k}|} \sum_{j \in S_{n,k}} \frac{1}{4} \sum_{r=1}^4 H_{n,j}^{(r)}. \quad (3.3)$$

由于没有人工词级起止时间戳，本文不宣称获得 `gold` 词边界。实际实现采用单调词序分配与 CTC 后验筛选 [12]：先按词元长度和标点停顿构造相对时长，再将其累计映射到视频时长；对存在声学候选的片段保留 CTC 路径，平均后验低于 0.50 的样本不进入文本有效窗口。此处的“对齐”指可复现的弱或半强约束，而不是人工验证级强制对齐。

3.3.2 语音窗口特征提取

音频先由 PyAV 转换为 16 kHz、单声道浮点 PCM。每个公共窗口内部使用 25 ms 帧长、10 ms 帧移和 512 点 FFT。74 维描述符由以下部分组成：

- (a) 20 维 MFCC 的均值和标准差，共 40 维，用于表征谱包络与发音差异 [13]；
- (b) 12 维 Chroma 的均值，共 12 维，用于捕捉音高类别和和声结构；

- (c) 频谱质心、带宽、滚降点、平坦度、谱熵、谱通量、低频能量比和高频能量比的均值与标准差，共 16 维；
- (d) 70–400 Hz 谱峰基频的均值和标准差，共 2 维；
- (e) 过零率和 RMS 能量的均值和标准差，共 4 维。

语音特征既包含相对稳定的谱结构，也包含表达情绪时常见的能量、音高和发声变化。对于音频末端未被真实解码覆盖的窗口，保留窗口位置但令掩码为 0。这一处理使模型可区分“低能量但存在的声音”与“根本没有有效音频”。

3.3.3 视觉关键帧特征提取

视觉特征从窗口中心附近真实帧提取。首先将视频帧缩放至宽度不超过 320 像素，随后使用传统人脸检测获取人脸存在性和归一化框几何；同时计算全帧亮度、HSV 颜色、边缘、梯度、拉普拉斯和图像熵等统计；最后通过相邻窗口或稠密光流构造运动量。35 维特征的组成见表 3.3。

表 3.3 35 维视觉特征构成

组别	描述	维数
人脸	存在性、归一化中心、宽高、面积比例等	6
全帧外观	亮度统计、HSV 颜色统计	12
纹理与边缘	边缘、梯度、拉普拉斯响应和图像熵	5
运动	稠密光流的水平、垂直、幅值及稳定性	4
局部结构	人脸或中心区域亮度、左右对称性与局部差异	8

视觉没有检测到人脸不等价于视觉模态缺失，因为背景亮度、运动和颜色仍可能对情感判断有贡献。因此仅将人脸相关特征置为相应值，只有无法解码真实帧时才将整个视觉窗口掩码为 0。

3.4 对齐结果与典型样本核验

3.4.1 时间结构与模态覆盖率核验

最终输出包含 5000 个公共窗口。时间结构核验显示，100% 样本的第一个窗口从 0 开始，100% 样本的窗口连续，100% 样本的最后一个窗口终点等于媒体实际时长，窗口正时长率为 100%。词级记录共有 1629 条，边界越界率、非正时长率、非单调率和重叠率均为 0。

模态覆盖率如图 3.2 所示。语音有效窗率 **99.00%**，视觉有效窗率 **99.80%**，文本有效窗率 **58.68%**，反映转写、声学支持与保守屏蔽规则共同造成的缺失。文本缺失被显式保留并由模型掩码处理，而不是被错误填成全程有效。




图 3.2 公共时间窗覆盖率与文本对齐审计

3.4.2 典型样本的跨模态时间对应

选取时长接近中位数且音视频覆盖完整的样本-tPCytz4rww\$_\$18 进行可视化。该样本原始转写为 “Do so and as well you’ll also want to remove any clutter from that you’ve accumulated.”，时长为 6.644987 秒，单窗宽度约为 0.132900 秒。图 3.3 上半部分显示 50 个等宽公共窗口，下半部分展示五个代表窗口中心附近的真实视频帧；表 3.4 同时列出这些窗口的文本片段、语音真实覆盖比例和视频帧时间戳。窗口色块仅示意边界和顺序，不是模拟的语音信号。为避开视频自带的外文下沿水印，图示视频帧统一裁切下缘约 13%，原始视频帧及证据定位文件均保持不变。由此可以同时核验文本词序、语音覆盖和视觉帧是否落在同一公共时间窗内。




图 3.3 典型样本的 50 窗时间轴与视频帧

表 3.4 典型样本的文本、语音和视频窗口对应关系

窗口	公共时间段 (s)	文本片段	语音有效	语音覆盖率	视频帧时间 (s)
0	0.000000–0.132900	无	1	0.999814	0.066667
12	1.594797–1.727697	and as	1	0.999814	1.666667
25	3.322494–3.455393	want to	1	0.999814	3.400000
37	4.917290–5.050190	that	1	0.999814	5.000000
49	6.512087–6.644987	无	1	0.427014	6.566667

3.4.3 缺少人工词级真值的评价边界

本题数据没有人工词级 gold timestamp，因此不能计算词起点 MAE、词终点 MAE、 $\pm 10/20/50$ ms 命中率或词区间 IoU。CTC 后验均值 0.912124 和中位数 0.982779 是模型内部置信信号，不是人工准确率。本文将这些数值用于质量审计，不把它们写成对齐准确率。后续可抽取约 20 条样本标注词边界，以评价真实边界误差。

4 问题二：局部模态缺失下的鲁棒情感预测

4.1 问题二分析

问题二的缺失发生在文本、语音或视觉的局部连续时间窗，不能把缺失模态简单理解为整条样本完全没有该模态。模型必须同时输出离散极性与连续强度，并比较缺失类型、位置和时长的影响。为避免将填充值误当作情感证据，本文在公共时间轴上显式传递有效掩码；为避免不同特征版本造成虚假增益，训练、验证与附件 3 推理还必须遵守一致的输入协议。求解顺序为建立掩码感知融合模型、确定联合训练目标、在附件 2 验证集选模，再进行局部遮挡和无标签附件 3 推理。

图 4.1 将这一求解顺序收束为四步。先锁定附件 2 的划分和特征版本，再以训练集统计量处理掩码特征；模型同时输出极性与强度，验证选模后才开展缺失敏感性实验和附件 3 推理。




图 4.1 问题二的掩码融合、双任务预测与缺失检验流程

4.2 模型建立：掩码感知的时序融合

4.2.1 固定基线与模型设计依据

固定对齐 baseline 将三个模态在 50 个窗口上的统计表示直接输入浅层融合网络，用于建立“已有特征是否本身可用”的参照。它的优点是参数少、训练快、易于复现；不足是无法区分模态内部不同时间窗的重要性，也不能自然地表示模态缺失。本文设计复杂主模型的目标不是盲目增加参数，而是逐层回答三个问题：哪个模态在当前样本中更有用、哪个时间窗贡献更大、情感类别和强度如何共享信息。

4.2.2 训练集统计量与掩码归一化

设训练集统计量为 $\mu^{(q)}, \sigma^{(q)}$ ，则模态 q 的归一化特征为

$$\tilde{z}_{n,k}^{(q)} = m_{n,k}^{(q)} \cdot \text{clip} \left(\frac{z_{n,k}^{(q)} - \mu^{(q)}}{\sigma^{(q)}}, -10, 10 \right). \quad (4.1)$$

其中 $\mu^{(q)}$ 与 $\sigma^{(q)}$ 只由训练集有效窗口计算。式 (4.1) 的关键是先归一化再乘 **mask**，避免缺失窗口影响统计量；同时保留 $m_{n,k}^{(q)}$ 作为网络输入。

4.2.3 三路双向 GRU 时序编码

对于模态 q ，先使用线性投影将原始维度映射到隐藏维度 $d = 128$ ：

$$e_{n,k}^{(q)} = \text{GELU}(W_q \tilde{z}_{n,k}^{(q)} + b_q) \odot m_{n,k}^{(q)}. \quad (4.2)$$

随后使用两层双向 GRU，其门控循环单元沿用序列建模中的门控状态更新思想 [14]。对正向和反向隐藏状态分别记为 $\vec{h}_{n,k}^{(q)}$ 与 $\overleftarrow{h}_{n,k}^{(q)}$ ，拼接后得到

$$h_{n,k}^{(q)} = \text{LayerNorm}\left(e_{n,k}^{(q)} + \text{Dropout}\left([\vec{h}_{n,k}^{(q)}; \overleftarrow{h}_{n,k}^{(q)}]\right)\right) \odot m_{n,k}^{(q)}. \quad (4.3)$$

双向结构能够同时利用窗口前后的局部变化，对短视频中“先铺垫后转折”的情绪表达尤其重要；残差加法使投影后的瞬时特征不会被循环状态完全覆盖。

实现中，缺失窗口在进入 GRU 前被置零，在残差输出和注意力池化时再次由 **mask** 排除。这保证无效窗口不会直接获得注意力权重；但 GRU 仍按完整 50 窗顺序递推，隐藏状态可能穿过缺失位置，因此该实现不等价于按有效长度压缩序列。本文的缺失实验检验的是这一具体实现的响应，不将其表述为完全消除了缺失窗口对状态传播的影响。

4.2.4 有效时间窗注意力

对每个模态使用一个线性评分器得到窗口得分。注意力机制为不同时间位置分配可学习权重，其基本思想可追溯至序列对齐研究 [15]：

$$s_{n,k}^{(q)} = w_q^\top \text{LayerNorm}(h_{n,k}^{(q)}) + b_q. \quad (4.4)$$

对掩码为 0 的位置施加负无穷屏蔽，并归一化为

$$\alpha_{n,k}^{(q)} = \frac{m_{n,k}^{(q)} \exp(s_{n,k}^{(q)})}{\sum_{j=1}^K m_{n,j}^{(q)} \exp(s_{n,j}^{(q)}) + \epsilon}. \quad (4.5)$$

模态级池化表示为

$$p_n^{(q)} = \sum_{k=1}^K \alpha_{n,k}^{(q)} h_{n,k}^{(q)}. \quad (4.6)$$

因此 α 既参与预测，也提供局部证据排序的第一层候选。需要强调的是，注意力不是因果解释；本文还会用遮挡实验检验注意力最高位置是否比随机位置更影响预测。

4.2.5 样本级动态模态门控

将三种模态池化表示拼接为 $p_n = [p_n^{(t)}; p_n^{(a)}; p_n^{(v)}]$ ，门控网络输出

$$g_n = W_2 \text{GELU}(W_1 \text{LayerNorm}(p_n) + b_1) + b_2. \quad (4.7)$$

$$\beta_n = \text{softmax}(\mathbf{g}_n). \quad (4.8)$$

其中 $\beta_n^{(q)} \geq 0$ 且 $\sum_q \beta_n^{(q)} = 1$ 。门控后的融合输入为

$$\mathbf{f}_n = [\beta_n^{(t)} \mathbf{p}_n^{(t)}; \beta_n^{(a)} \mathbf{p}_n^{(a)}; \beta_n^{(v)} \mathbf{p}_n^{(v)}]. \quad (4.9)$$

这样，模型可以针对不同样本自适应改变模态作用程度：例如语音缺失时，音频门控可能降低；文本证据完整时，文本门控可能提高。但门控权重仍是模型内部的相对贡献，不等同于人类心理机制。

4.2.6 融合表示与分类回归双输出

融合层采用“线性扩展—GELU—Dropout—线性压缩—LayerNorm”的结构：

$$\mathbf{r}_n = \text{GELU} \left(\text{LayerNorm} \left(W_f^{(2)} \text{Dropout}(\text{GELU}(W_f^{(1)} \mathbf{f}_n + b_f^{(1)})) + b_f^{(2)} \right) \right). \quad (4.10)$$

分类头与回归头分别为

$$\hat{\mathbf{p}}_n = \text{softmax}(W_c \mathbf{r}_n + b_c). \quad (4.11)$$

$$\hat{y}_n^{(r)} = W_r \mathbf{r}_n + b_r. \quad (4.12)$$

训练损失取交叉熵与 Smooth L1 回归损失的加权和。共享表示、分任务输出及反向传播属于深度学习的常见联合训练框架 [16]：

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + \lambda_r \mathcal{L}_{\text{SmoothL1}}, \quad \lambda_r = 0.5. \quad (4.13)$$

最终模型按验证集综合分数 $F1_{\text{macro}} - 0.1 \times MAE$ 选择最优轮次，同时保留 Accuracy、Pearson 和解释指标供审查。

4.2.7 网络结构与参数规模

图 4.2 展示了模型结构。每个模态包含一个输入投影、两层双向 GRU 和时间注意力，三路输出再通过门控和融合层产生两个任务的结果。对长度 K 、隐藏维度 d 、模态数 $M = 3$ 的输入，三路 GRU 的时间计算量约为 $O(MKd^2)$ ，注意力与门控的计算量分别约为 $O(MKd)$ 和 $O(Md^2)$ 。与简单拼接相比，增加的计算主要用于捕捉时间依赖和模态相对作用，仍远小于端到端视频 Transformer 的时空注意力复杂度。



图 4.2 层次化多模态情感预测模型

4.3 模型训练与实验协议

4.3.1 联合目标与训练流程

算法 1 给出训练和验证的核心步骤。特别地，归一化统计量先从训练集计算；模型保存依据验证集，不读取附件 3 或附件 4 标签。

算法 1 统一接口下的层次化多模态双任务训练

输入：训练集 D_{tr} 、验证集 D_{va} ，三模态特征与掩码

输出：最优 checkpoint、验证指标与训练历史

- 1: 用 D_{tr} 有效窗口计算每个模态的 $\mu^{(q)}, \sigma^{(q)}$
 - 2: 对所有样本执行式 (4.1)，保留 $m^{(q)}$
 - 3: 初始化三路 BiGRU、时间注意力、门控、融合层和双任务头
 - 4: **for** epoch = 1, ..., E **do**
 - 5: **for** mini-batch $B \subset D_{tr}$ **do**
 - 6: 计算三路编码 $h^{(q)}$ 与掩码注意力 $\alpha^{(q)}$
 - 7: 计算模态门控 β 、融合表示 r 与两项预测
 - 8: 按式 (4.13) 计算损失，反向传播并更新参数
 - 9: 在 D_{va} 上计算 Accuracy、Macro-F1、MAE、Pearson
 - 10: 若 $F1_{macro} - 0.1MAE$ 提升，则保存当前模型
 - 11: 返回验证分数最高的 checkpoint
-

4.3.2 统一输入接口与数据用途

为了保证比较可解释，本文把固定 aligned baseline、长度感知重采样 baseline、无标签表征融合、双向 GRU 融合、旧残差融合和统一编码最终模型分开报告。固定 baseline 使用原始 aligned_features.pkl，最终模型使用 aligned_text_bert_features.pkl；两者的附件 2 验证划分相同，但文本特征并不相同。因此跨模型的四项差异是系统级对比，不是“仅改变网络架构”的控制实验；统一接口的合规性专指最终模型自身训练、验证与专项推理一致。旧残差模型的附件 2 训练与附件 3 文本重建使用了不同接口，因此只作为历史指标对照，不作为最终模型。

附件 2 训练集和验证集只参与监督学习与模型选择，附件 2 test 划分只作独立复核；附件 3 无标签，只输出预测分布和缺失敏感性；附件 4 无标签，只输出预测及解释证据。任何无标签附件均不用于反向选模。

4.3.3 监督样本划分与类别比例

统一编码特征文件中，训练集、验证集和独立 test 划分分别包含 3395、728 和 727 条带标签样本。三类情感的数量存在一定不均衡：训练集 Negative、Neutral、Positive 分别为 967、758 和 1670；验证集分别为 206、184 和 338；test 分别为 207、158 和 362。Positive 占比最高，Neutral 相对较少，因此仅报告 Accuracy 可能掩盖少数类性能，本文坚持同时报告 Macro-F1。

表 4.1 附件 2 监督数据的划分与类别结构

划分	样本数	Negative	Neutral	Positive	Negative 占比	Neutral 占比	Positive 占比
Train	3395	967	758	1670	28.48%	22.33%	49.19%
Valid	728	206	184	338	28.30%	25.27%	46.43%
Test	727	207	158	362	28.47%	21.73%	49.79%

训练、验证和 test 的类别比例总体接近，但 Neutral 在 test 中进一步减少。图 4.3 的分段百分比由表 4.1 的实际类别计数计算。这一结构解释了为什么 Accuracy 较高并不能自动表示模型在三类上均衡；Macro-F1 在模型选择中具有更强的约束作用。连续强度标签范围均为 $[-3, 3]$ ，因此回归头使用 Smooth L1 而不是直接使用未截断的平方损失，以减弱极端强度样本对训练的影响。




图 4.3 附件 2 监督数据的类别构成

4.3.4 训练与推理接口一致性审计

本文把合规性拆解为数据接口、统计量、模型选择和专项推理四个可检查层次。表 4.2 不是泛泛的工程说明，而是最终模型能够被复核的原因：每一项都有固定文件、固定规则和明确的失败条件。

表 4.2 最终模型统一接口审计矩阵

层次	统一内容	审计证据	失败时的处理
文本输入	token 形式的 text_bert、固定 DistilBERT revision、最后四层均值	manifest 中的模型名、revision 与特征规则	生成新 manifest，不得复用旧 checkpoint
时间输入	音频、视觉均使用 aligned_50，文本也输出 50 窗表示	派生特征文件与 50 窗形状检查	重新对齐并更新 SHA-256
归一化	均值、方差只由训练集有效窗口计算	checkpoint 中的 normalizers 字段	禁止使用验证或附件数据估计
模型选择	以验证集 Macro-F1 和 MAE 综合分数选择轮次	validation.json 与训练历史	test 结果不得反向调参
专项推理	附件 3/4 只输出预测、缺失或解释证据	CSV、JSON、关键帧 manifest	不计算无标签监督指标

4.3.5 分类回归联合选择准则

最终模型的验证选择分数定义为

$$S = F1_{macro} - 0.1 \times MAE. \quad (4.14)$$

固定 baseline 的分数为 $0.588115 - 0.1 \times 0.616443 = 0.526471$ ；严格统一编码基础候选的分数为 $0.578397 - 0.1 \times 0.632199 = 0.515177$ ；最终注意力一门控模型的分数为 $0.601580 - 0.1 \times 0.612262 = 0.540354$ 。旧 residual 模型的分数虽然为 0.547936，但其文本接口不满足专项推理一致性要求，因此不能仅按分数选为最终模型。

这种选择方式体现了两个原则。第一，分类不只看总体正确率，而要兼顾少数类。第二，回归不只看相关性，而要控制绝对误差。将两者放在同一选择分数中并不意味着它们可以被解释为同一种物理量，而是提供一个可复现的模型排序规则；最终表格仍保留四个原始指标，避免综合分数掩盖单项变化。

4.4 模型求解与验证集性能

4.4.1 候选模型的验证集筛选

表 4.3 汇总六种候选模型在附件 2 同一验证划分上的单次实验结果。它们的文本表示、时间组织和训练过程并不完全相同，因此先说明每种方法解决的问题，再比较其分类与回归指标；表中数值不能被解释为仅改变一个网络模块的消融实验。

表 4.3 候选模型在附件 2 验证集上的结果

模型	Accuracy	Macro-F1	MAE	Pearson	备注
Fixed aligned baseline	0.612637	0.588115	0.616443	0.624582	简单参照
Length-aware resampled baseline	0.614011	0.595798	0.614132	0.620838	数据版本候选
Label-free SSL fusion	0.608516	0.578294	0.667391	0.573212	不选用
Bidirectional SSL fusion	0.618132	0.598285	0.621818	0.588408	对比模型
Old residual fusion	0.622253	0.610330	0.623941	0.601396	接口不合规对照
Final attention-gate model	0.637363	0.601580	0.612262	0.629628	最终主模型

固定对齐基线。该模型直接使用附件 2 预计算的对齐文本表示、语音和视觉特征。每路经线性投影、局部一维卷积和掩码均值池化，再拼接输入浅层双任务输出；局部卷积能够利用相邻窗口，却没有独立的长程序列编码、时间注意力或动态门控。它以 0.588115 的 Macro-F1 和 0.616443 的 MAE 提供固定参照，不能因为结构简单就把其回归表现忽略。

长度感知重采样基线。该路线先依据未对齐序列的有效长度，将各模态重采样到 50 个窗口，再使用基线预测网络；它主要改变时间组织，而非引入更复杂的融合器。相对固定对齐基线，Macro-F1 提高 0.007683、MAE 下降 0.002311，但 Pearson 从 0.624582 降至 0.620838。这说明重采样在当前验证划分上改善了部分指标，不能据此认定所有回归性质都更好。

无标签自监督融合。该候选先在未对齐数据上通过时间遮挡、特征扰动和表征约束学习单模态 GRU 编码器，再将其用于对齐数据上的监督融合。无标签预训练不直接优化情感极性或强度；在这组结果中，Macro-F1 为 0.578294、MAE 为 0.667391，均劣于固定基线。它说明泛用表征并不会自动保留对情感判别最有用的细节。

双向自监督融合。在上述路线中使用双向 GRU，使每个窗口同时接收前后语境。其 Accuracy 和 Macro-F1 达到 0.618132 和 0.598285，分类指标高于固定基线；但 MAE 为 0.621818、Pearson 为 0.588408，回归表现没有同步改善。双向上下文带来的分类收益不足以支持“四指标全面提升”的结论。

旧残差融合。该模型保留自监督编码器，并增加原始对齐特征的掩码均值和标准差旁路，旁路投影以零初始化，使网络起初不破坏原融合表示。它在历史验证记录中取得 0.610330 的 Macro-F1，为本表最高；然而 MAE 为 0.623941，高于固定基线，而且附件 2 训练与附件 3 文本重建使用了不同接口。因此该结果只保留作结构与指标取舍的历史对照，不进入最终合规模型排序。

最终注意力一门控模型。该模型固定使用同一 revision 的 DistilBERT 重建 text_bert 表示，将三路双向 GRU、有效窗口时间注意力和样本级门控连接到分类与强度回归双头。相对固定基线，Accuracy 和 Macro-F1 分别增加 0.024726 和 0.013465，MAE 下降 0.004181，Pearson 增加 0.005046；四项方向均有利，且训练与专项推理接口一致。两者文本特征版本不同，这些差异只支持完整系统比较，不构成门控或注意力单项增益的证明。

从指标取舍看，重采样与双向自监督融合均提高了 Macro-F1，但只有重采样同时降低 MAE；旧残差融合的 Macro-F1 最高，却有接口不一致和回归误差较高的问题。最终模型的 Macro-F1 低于旧残差融合 0.008750，但在合规候选中同时取得最高 Accuracy、最高 Pearson 和最低 MAE。因而最终选择依据是接口一致条件下的多指标平衡，而非任一单项指标的最大值。

图 4.4 将固定基线、重采样基线、双向 GRU 对照和最终模型的四项指标分开展示；未通过统一输入接口审计的旧残差方案仅保留在表 4.3 中。图中各面板采用各自的数值刻度，应结合表中原值比较，不能只按标记间距判断改进幅度。




图 4.4 四类候选模型在同一验证划分上的指标；输入特征不同，各面板采用独立局部刻度

图 4.5 聚焦固定 baseline 和最终模型在附件 2 验证集上的四项指标 ($n = 728$, 单次训练记录)；MAE 越低越好，其他三项越高越好。固定 baseline 与最终模型的文本特征版本不同，因此图示仅为描述性的完整系统比较，不构成架构单因素消融或显著性推断。




图 4.5 固定基线与最终模型在附件 2 验证集上的指标水平与定向变化；文本特征版本不同

4.4.2 极性分类与强度回归结果

最终模型相对于固定 baseline 的变化量为

$$\Delta Acc = 0.637363 - 0.612637 = 0.024726, \quad (4.15)$$

$$\Delta F1 = 0.601580 - 0.588115 = 0.013465, \quad (4.16)$$

$$\Delta MAE = 0.612262 - 0.616443 = -0.004181, \quad (4.17)$$

$$\Delta \rho = 0.629628 - 0.624582 = 0.005046. \quad (4.18)$$

其中 MAE 下降表示连续强度误差变小，其他三个指标上升表示分类或相关性增强。两模型共享附件 2 验证划分但文本特征来源不同；以上差异可用于完整管线的数值比较，不能拆解为架构本身的增益，也不能自动解释为外部数据的因果提升。

4.4.3 分类混淆与强度误差诊断

图 4.6 给出最终模型在附件 2 验证集的三分类混淆矩阵：行表示真实类别，列表示预测类别；每格同时标注样本数和该真实类别内的比例，总计 $n = 728$ 。消极、积极两类的召回率分别为 $133/206 = 64.6\%$ 和 $262/338 = 77.5\%$ ，中性仅为 $69/184 = 37.5\%$ 。尤其有 84 条中性样本被判为积极，占真实中性样本的 45.7%；这说明总体 Accuracy 不能代表三类同等可靠，也是报告 Macro-F1 并保留中性类误差分析的原因。




图 4.6 最终模型验证集混淆矩阵

图 4.7 展示同一验证集的情感强度真实值和预测值；虚线表示理想一致，图中 Pearson 和 MAE 与保存的验证指标一致。真实强度跨越 $[-3, 3]$ ，而预测值在该划分中介于 $[-2.046, 1.668]$ 。对于真实强度不小于 2 的 43 条样本，预测均值仅为 0.827；这一收缩现象说明模型对强烈积极表达仍倾向于低估。散点图反映的是误差形态，相关性 0.630 不能被解释为每条样本都接近理想线。

按真实极性分层重算逐样本回归绝对误差，Negative、Neutral、Positive 三组的 MAE 分别为 0.7358、0.4539 和 0.6232；对应分类召回率为 64.56%、37.50% 和 77.51%。Neutral 组的回归误差最低，却有超过六成样本被分错类。这一差异来自分类头与回归头的不同判别目标，也表明不能用回归 MAE 替代少数类的分类诊断；上述分层值由同一份 728 条验证预测记录计算，未引入新的测试集或选模步骤。




图 4.7 最终模型验证集强度回归散点图（附件 2 验证集，728 例）

4.5 局部缺失实验与附件 3 推理

4.5.1 缺失类型、位置与时长敏感性

严格统一编码候选在 clean 条件下的 Accuracy 为 0.619505、Macro-F1 为 0.578397、MAE 为 0.632199、Pearson 为 0.617068。分别遮挡文本、音频或视觉的中间 15 个窗口，得到如下变化：

表 4.4 中间 15 个窗口缺失敏感性

场景	Accuracy	Macro-F1	MAE	Pearson
Clean	0.619505	0.578397	0.632199	0.617068
Text middle 15 masked	0.622253	0.581936	0.636871	0.616090
Audio middle 15 masked	0.625000	0.583555	0.632317	0.616877
Vision middle 15 masked	0.619505	0.577290	0.632722	0.616544

该表并非最终模型的性能替代，而是对严格统一接口候选的敏感性审计。中间视觉窗口屏蔽造成 Macro-F1 轻微下降，文本中间窗口屏蔽在该验证集上未造成分类下降，但会改变回归误差；这说明“有效窗口数量”与“任务相关性”并不等价。由于每条样本固定为 50 个公共窗口，遮挡 5、15、25 个连续窗口分别对应 10%、30%、50% 的局部缺失率。图 4.8 汇总各模态中间 15 窗（30% 缺失率）的分类变化；图 4.9 进一步按文本、语音、视觉及起始、中间、末尾位置展示 10%、30%、50% 缺失率下的 Macro-F1 相对 clean 值变化，格内单位为百分点。文本起始 50% 缺失时下降 15.63 个百分点，起始 30% 缺失时下降 7.96 个百分点；相同缺失率的中段或末段遮挡远未呈现这种下降，说明缺失位置与缺失率必须一起分析。两图都只针对严格统一编码候选，而非最终模型；缺失测试记录掩码敏感性，不意味着所有遮挡必然降低准确率。




图 4.8 15 窗口模态屏蔽敏感性

文本 · 起始	-2.85	-7.96	-15.63
文本 · 中段	+0.11	+0.35	-0.58
文本 · 末段	+0.00	-0.27	+0.92
语音 · 起始	-0.70	+0.91	+0.48
语音 · 中段	-0.35	+0.52	-0.39
语音 · 末段	+0.00	+0.01	+0.14
视觉 · 起始	+0.71	+1.20	+0.91
视觉 · 中段	+0.00	-0.11	-0.39
视觉 · 末段	-0.11	-0.65	-0.28
	5	15	25
	被遮挡窗口数		

图 4.9 不同位置和时长遮挡后的 Macro-F1 变化（百分点）

4.5.2 逐模态窗口遮挡响应

严格统一编码候选提供了多个窗口屏蔽场景。本文选择每个模态中间 15 个窗口进行分析，因为中间位置同时包含较长的上下文，能够检验模型是否过分依赖视频开头或结尾。图 4.8 给出 Accuracy 和 Macro-F1 下降量，表 4.5 给出对应的回归变化。

表 4.5 15 窗口屏蔽的相对变化量

场景	Δ Accuracy	Δ Macro-F1	Δ MAE	Δ Pearson
Text middle 15	+0.002747	+0.003539	+0.004672	-0.000977
Audio middle 15	+0.005495	+0.005158	+0.000117	-0.000191
Vision middle 15	0.000000	-0.001107	+0.000523	-0.000503

这些结果不能简单解读为“屏蔽后性能提高”，因为某些窗口可能包含噪声或与目标无关的信息。更合理的结论是：模型在当前验证集上没有把所有中间窗口都视为必要证据。对于中间 15 窗，视觉遮挡的 Macro-F1 变化为 -0.001107，文本遮挡的 MAE 增加 0.004672；然而图 4.9 表明文本起始段的损失要大得多。掩码机制提供了比“全部模态必须存在”更现实的缺失建模方式，但该实验仍只是单一模型、单一划分的局部敏感性探针。

4.5.3 附件 3 无标签样本预测

附件 3 没有分类或连续强度真值，因此只报告 30 条统一编码正式候选的预测分布：Negative 6 条、Neutral 3 条、Positive 21 条，平均预测强度为 0.185826。这个分布只能说明专项输入下模型输出的结构，不能被写成 Accuracy 或 F1。文本全屏蔽的敏感性对照也只用于观察预测稳定性，不参与阈值或模型选择。

附件 3 专项实验还比较了对齐版本和未对齐版本。旧接口探索性结果在对齐版本中预测 Negative 2、Neutral 6、Positive 22，平均强度 0.436542；未对齐版本同样为 Negative 2、Neutral 6、Positive 22，平均强度 0.464932。由于没有标签，这些数值只作为输出分布记录。最终论文将严格统一编码候选和旧接口探索性结果分栏，避免把不同特征版本混为一谈。

表 4.6 附件 3 统一编码正式候选的全量预测结果

文件	预测类别	预测强度
附件 3_01.pkl	Negative	-1.007
附件 3_02.pkl	Neutral	-0.074
附件 3_03.pkl	Positive	0.320
附件 3_04.pkl	Positive	0.549
附件 3_05.pkl	Negative	-1.634
附件 3_06.pkl	Positive	1.114
附件 3_07.pkl	Negative	-0.204
附件 3_08.pkl	Negative	-0.736
附件 3_09.pkl	Positive	0.854
附件 3_10.pkl	Neutral	-0.245
附件 3_11.pkl	Positive	0.466
附件 3_12.pkl	Positive	0.234
附件 3_13.pkl	Positive	0.249

文件	预测类别	预测强度
附件 3_14.pkl	Negative	-0.526
附件 3_15.pkl	Positive	1.009
附件 3_16.pkl	Positive	1.078
附件 3_17.pkl	Positive	0.001
附件 3_18.pkl	Positive	0.885
附件 3_19.pkl	Neutral	0.347
附件 3_20.pkl	Negative	0.070
附件 3_21.pkl	Positive	-0.146
附件 3_22.pkl	Positive	-0.032
附件 3_23.pkl	Positive	0.120
附件 3_24.pkl	Positive	0.152
附件 3_25.pkl	Positive	0.718
附件 3_26.pkl	Positive	0.497
附件 3_27.pkl	Positive	0.618
附件 3_28.pkl	Positive	0.264
附件 3_29.pkl	Positive	-0.041
附件 3_30.pkl	Positive	0.675

4.6 独立测试与误差复核

4.6.1 附件 2 测试集的独立复核

附件 2 test 划分的可追溯结果包括：固定 aligned baseline 的 Accuracy、Macro-F1、MAE、Pearson 分别为 0.650619、0.604127、0.657608、0.653185；旧 residual fusion（回归权重 1.0）为 0.657497、0.612718、0.673889、0.654312；unaligned_resampled_50 长度感知重采样候选为 0.664374、0.617797、0.649980、0.655419。最后一组数值来自另一种特征组织版本，不能标注为最终统一编码可解释模型的 test 结果；当前实验目录没有该最终模型的可审计 test 预测文件。

这一区分非常重要：验证集用于选择最终模型并支持本文的主结论，test 划分只用于独立复核和候选方案比较。测试集上的重采样候选四项均优于 aligned baseline，但它与最

终模型的输入版本不同，不能据此改写主模型结论，也不使用 test 结果反向调参。

在另一 Windows 环境中，使用保存的 aligned_baseline.pt 对附件 2 的 727 条 test 样本复算，得到 Accuracy 0.650619、Macro-F1 0.604127、MAE 0.657608、Pearson 0.653185，与原记录逐位一致。相同环境以 seed 42 重新训练固定基线，验证集 Macro-F1 为 0.585552，较保存权重的 0.588115 低 0.002563；其 test Macro-F1 为 0.596685。这区分了“固定权重可复算”和“重新训练数值完全相同”两种复现要求，且新权重未用于本文最终模型选择。

4.6.2 验证集收益与测试集波动

验证集上最终模型四项指标均超过固定 baseline；独立 test 只报告已有 checkpoint 和数据版本能够复核的候选结果。表 4.7 将两种数据用途并列展示。

表 4.7 验证集最终模型与测试集可追溯候选结果

模型与数据划分	Acc	F1	MAE	ρ
Fixed aligned baseline (validation)	0.6126	0.5881	0.6164	0.6246
Final attention-gate model (validation)	0.6374	0.6016	0.6123	0.6296
Fixed aligned baseline (test)	0.6506	0.6041	0.6576	0.6532
Length-aware resampled baseline (test)	0.6644	0.6178	0.6500	0.6554
Residual fusion, 回归权重 1.0 (test)	0.6575	0.6127	0.6739	0.6543

从具体数值看，验证集上 Final attention-gate model 相对于 Fixed aligned baseline 的 Accuracy 由 0.6126 升至 0.6374，Macro-F1 由 0.5881 升至 0.6016，MAE 由 0.6164 降至 0.6123，Pearson 由 0.6246 升至 0.6296。test 上，unaligned_resampled_50 候选相对于 aligned baseline 的四项变化分别为 +0.0138、+0.0137、-0.0076 和 +0.0022；Residual fusion（回归权重 1.0）相对于 aligned baseline 的 Accuracy、Macro-F1 和 Pearson 略升，但 MAE 增加 0.0163。由于测试候选的输入版本和训练接口不同，本文主张仍限定为“统一接口最终模型在附件 2 验证集四项优于固定 baseline”，不把测试候选的优势归因于最终模型，也不主张所有外部样本四项均优于。这样的表述与当前 checkpoint、JSON 和测试报告能够相互追溯。

4.6.3 单次划分的统计推断边界

本文当前训练记录主要来自固定随机种子 42 的单次训练，因此不能把一个验证集差值直接写成跨种子显著性。由于数据量较大，指标可作为工程比较依据；但如果需要统计推断，应重复不同 seed，或者进行分层交叉验证并报告均值、标准差和置信区间。本文选择

不虚构置信区间，将重复实验列为后续工作，并把可复现的 `seed`、`checkpoint` 和原始 JSON 作为审计证据。

综合数据划分、接口审计、缺失敏感性与独立测试可见，最终模型的价值在于自身各阶段输入一致，并在指定验证集上兼顾分类、回归和局部缺失响应；单次划分不能支持跨种子显著性或全面泛化结论。

5 问题三：模态与时间窗贡献的可解释预测

5.1 问题三分析

问题三要求在输出情感极性和强度的同时，说明当前判断主要依赖哪种模态以及哪些局部片段，并能回看原始媒体。最终模型已有样本级门控权重和模态内注意力，但权重大小本身不能证明某段输入真的影响预测。因此，本文先用模态消融估计作用程度，再用时间窗遮挡检验局部敏感性，将证据索引映射回视频时间；最后在附件 2 验证集检验解释排序，在无标签附件 4 上输出预测和证据记录。解释对象是模型行为，不是人类情感的因果机制。

图 5.1 展示解释从主模型预测到证据交付的链条。门控与注意力给出候选线索，反事实消融和遮挡检验其对输出的实际影响，最后把高影响窗口映射回可回看的原始片段。




图 5.1 问题三的模态作用量化与局部证据追踪流程

5.2 解释模型建立与证据量化

5.2.1 沿用模型与解释训练协议

问题三沿用问题二中通过统一输入接口审计的最终 attention-gate 模型，不另行更换特征版本或网络主干。该模型由三路两层双向 GRU、有效窗口时间注意力、样本级模态门控、融合层以及分类和回归双头组成，联合目标仍为交叉熵与 Smooth L1 损失的加权和，隐藏维度、Dropout、学习率、批量大小和随机种子见表 C.1。训练阶段只使用附件 2 训练集，按照问题二的验证集综合分数选择 checkpoint；解释阶段不更新模型参数，只在附件 2 验证样本上检验证据排序，并将同一 checkpoint 用于附件 4 专项推理。该模型的验证集基础性能为 Accuracy=0.637363、Macro-F1=0.601580、MAE=0.612262、Pearson=0.629628，详见表 4.3 和图 4.5；本节新增的是解释有效性和证据定位评价。

5.2.2 模态作用程度的消融估计

对每个附件 4 样本，先得到完整输入的目标类别置信度 p_{full} ，再分别屏蔽文本、语音和视觉，得到 p_{-q} 。定义

$$\delta_q = \max(p_{full} - p_{-q}, 0). \quad (5.1)$$

为避免不同模态下降尺度影响比较，将三个非负下降值归一化：

$$\tilde{\delta}_q = \frac{\delta_q}{\sum_{r \in \mathcal{M}} \delta_r + \epsilon}. \quad (5.2)$$

在模型内部，门控权重 β_q 提供样本级相对作用；在报告中同时输出消融贡献和门控贡献，防止单独把注意力权重解释成因果贡献。

5.2.3 关键时间窗的反事实遮挡

对模态 q 的第 k 个窗口，将其特征置零并把掩码置为 0，保持其他模态和其他窗口不变。目标类别置信度下降为

$$\Delta_{q,k} = p_{full} - p_{q,k}^{mask}. \quad (5.3)$$

综合证据得分定义为

$$evidence_{q,k} = \alpha_{q,k} \cdot \tilde{\delta}_q \cdot \max(\Delta_{q,k}, 0). \quad (5.4)$$

对每条样本取 Top-6 证据，并将窗口索引转换为

$$[t_k, t_{k+1}) = \left[\frac{kT}{50}, \frac{(k+1)T}{50} \right). \quad (5.5)$$

视频证据再由 PyAV 按目标时间导出实际关键帧，清单记录源视频、目标时间、实际帧时间、误差和 SHA-256。

5.3 解释结果验证与典型样本

在附件 2 验证集随机抽取 128 条样本，对每个模态比较注意力最高窗口与一个随机窗口的置信度下降。最终结果为：最大影响窗口平均下降 **0.010919**，随机窗平均下降 **0.001215**，Top-Random 为 **0.009704**。正值表明注意力排序能够找到比随机位置更敏感的局部证据，但它仍然是模型行为解释，不等价于真实人类因果机制。




图 5.2 反事实解释验证与模态贡献

图 5.3 至图 5.5 对同一条附件 2 验证样本展示三个层次的模型行为。可视化样本按固定规则选取：顺序扫描验证集，取首条分类正确、三模态均有效、且注意力最高窗口遮挡后置信度下降不低于 0.01 的样本。阈值只用于展示清晰案例，不用于估计总体解释性能；总体检验仍以 128 条抽样实验为准。图 5.3 中橙色轮廓标出每个模态注意力最高的窗口，灰色小点表示无效位置；在这条样本中，文本注意力集中于第 22 窗，后段文本窗口无效，因而不能把空白处解释为模型“不关注”。图 5.4 按原始门控权重从大到小依次屏蔽模态：原类别置信度从 0.819 降至 0.225，继续屏蔽视觉后为 0.152，而最后屏蔽语音略回升至 0.153。横条是该顺序下的实测变化，不是三个独立效应的可交换加和。图 5.5 汇总真实与预测类别、置信度、模态门控及遮挡证据前三窗；文本门控 0.622 与第 22 窗遮挡下降 0.034 相互支持，但两者仍只能解释模型行为。原始样本 ID 和逐项数值保留在对应数据文件中。




图 5.3 示例样本时间注意力热力图




图 5.4 示例样本顺序模态消融瀑布图

验证集代表性样本：第6条

真实：消极 预测：消极 置信度：0.819

模态门控权重

文本 0.622

语音 0.131

视觉 0.247

局部遮挡敏感证据：前三窗口

1. 文本 第22窗 得分 0.00407 下降 +0.034

2. 语音 第02窗 得分 0.00001 下降 +0.001

3. 视觉 第02窗 得分 0.00000 下降 +0.000

展示规则：首条分类正确、三模态均有效且最高注意力窗口遮挡后置信度下降至少 0.01 的样本。

图 5.5 示例验证样本解释卡

5.4 附件 4 预测与证据追踪

5.4.1 极性与强度预测分布

附件 4 共 20 条无标签样本。根据最终模型的 q3_predictions.csv 逐项核对，预测类别 Negative、Neutral、Positive 分别为 8、3、9 条，连续强度平均值为 -0.131304。图 5.6 的右侧每个点对应一条独立样本，颜色表示预测极性，纵坐标表示回归强度；样本序号没有时间连续性，因此不连接相邻点。20 条样本的预测强度介于 -2.108 和 1.218，负向预测中也有接近零的样本。极性类别与连续强度来自两个输出头，不能把强度正负当成类别标签的硬阈值。20 条样本的主模态均为文本；文本、语音、视觉门控权重均值分别为 0.662、0.181 和 0.157。虽然语音权重最高达到 0.409、视觉权重最高达到 0.274，两者均未成为该批样本的最大门控项。因此该批结果揭示了文本依赖倾向，不能作为三种模态主导地位均衡的证据。




图 5.6 附件 4 预测类别与强度分布

5.4.2 代表样本的预测核验

附件 4 无标签，但可以对结构化输出进行案例层面的人工复核。表 5.1 选择若干具有不同极性和强度的样本，记录类别、强度和三个门控贡献。表中正负强度并不是概率，而是连续回归头输出，因此可以出现负值。

表 5.1 附件 4 代表性样本的结构化预测

ID	类别	强度	主模态	文本	语音	视觉
01	Neutral	0.255	text	0.726	0.110	0.164
02	Negative	0.041	text	0.461	0.409	0.130
03	Neutral	-0.491	text	0.658	0.125	0.217
04	Negative	-0.594	text	0.611	0.115	0.274
05	Positive	1.022	text	0.709	0.109	0.182
06	Positive	0.052	text	0.550	0.298	0.152

案例复核有三个作用。第一，它证明模型输出不仅包含一个类别标签，还包含可供审阅的强度和模态贡献。第二，ID 02、04 的语音或视觉贡献相对上升，说明文本并非唯一通道。第三，ID 03 的负强度与 Neutral 类别并不矛盾，说明极性和强度是两个相关但不同的任务。由于缺少标签，本文不对这些个案作“预测正确”的判断，只报告结构化输出和解释字段。

5.4.3 证据字段与原始媒体对应

每条证据同时记录 attention score、modality contribution、occlusion drop 和 regression change。若某个窗口注意力高但遮挡下降接近 0，它会被综合证据分数压低；若注意力一般但遮挡后类别置信度显著下降，则该窗口仍可能进入 Top-6。这种乘积结构比单独使用注意力更谨慎。

$$\log evidence_{q,k} = \log(\alpha_{q,k} + \epsilon) + \log(\widetilde{\delta}_q + \epsilon) + \log(\max(\Delta_{q,k}, 0) + \epsilon). \quad (5.6)$$

在实际输出中不直接使用对数值，而保留原始分量，便于审阅者追溯。图 5.2 显示 Top 窗口的平均置信度下降约为随机窗口的 9 倍，说明解释排序至少在行为层面具有区分度。

5.4.4 视频关键帧与文本片段追踪

对附件 4 输出的 Top 证据，最终产生 29 张视觉关键帧，均来自原始 MP4 的 PyAV 解码。图 5.7 给出部分示例：为避开原视频下沿外文水印，展示图统一裁切下缘约 13%，证据清单引用的原始关键帧及散列值不变。文本证据仍采用转写词序与公共窗口的弱映射，因此在论文中只把它作为模型证据片段，不宣称词级真实时间定位。语音证据直接引用视频公共时间窗，具有更清晰的时间解释。




图 5.7 附件 4 高证据窗口对应的原始视频关键帧（仅裁切画面下缘）

5.4.5 解释结果的可复核性与局限

解释输出不是一张孤立的热力图，而是结构化记录：样本 ID、排名、模态、窗口编号、注意力分数、模态贡献、遮挡下降、证据分数、回归变化、起止时间、文本片段和帧路径。这样的记录可以被审阅者逐条复核，也可以在后续系统中转化为主要参考模态、关键时间

段和证据视频片段。

表 5.2 汇总 20 条附件 4 样本的 Top-1 证据；每条样本的完整 Top-6 记录仍保存在 q3_explanations.csv 中，共 120 条。表中时间区间按 50 窗公共时间轴归一化表示，视觉证据可由同一窗口索引追溯到关键帧清单，文本证据保留转写片段，语音证据使用对应公共时间窗。

表 5.2 附件 4 全部 20 条样本的 Top-1 证据摘要

ID	模态	窗口	归一化时间段	遮挡下降	文本片段
01	text	3	0.06–0.08	0.0128	these
02	text	18	0.36–0.38	0.1165	each
03	text	21	0.42–0.44	0.0032	just
04	text	25	0.50–0.52	0.3590	kiss
05	vision	7	0.14–0.16	0.0014	my
06	text	34	0.68–0.70	0.0136	might
07	text	48	0.96–0.98	0.0102	succeed
08	text	8	0.16–0.18	0.0376	brings
09	text	16	0.32–0.34	0.0016	like
10	text	30	0.60–0.62	0.0330	I'm
11	text	4	0.08–0.10	0.0040	would
12	text	41	0.82–0.84	0.0294	sag,
13	text	6	0.12–0.14	0.0101	could
14	text	33	0.66–0.68	0.0278	Uniform
15	vision	21	0.42–0.44	0.0049	education
16	text	10	0.20–0.22	0.0037	a
17	text	15	0.30–0.32	0.0027	your
18	text	29	0.58–0.60	0.1127	the
19	text	39	0.78–0.80	0.0085	imperfections,
20	text	38	0.76–0.78	0.0014	video

6 模型评价与适用边界

6.1 输入一致性与局部缺失鲁棒性

在多模态项目中，模型结构复杂并不自动意味着结论可信。若训练时使用预计算文本特征，附件 3 推理时又用另一套规则重建 768 维特征，则即使维度相同，也不能把输出当作同一模型的专项测试。本文将输入接口写成模型定义的一部分：文本编码器名称、revision、最后四层均值规则、有效 token 掩码、音频视觉的 aligned 版本以及训练集归一化统计量共同组成 feature manifest。任何改变都应产生新的版本号和新的结果表。

6.1.1 局部缺失机制与掩码响应

掩码的作用不是简单抹除信息，而是将信息不存在显式传递给模型。在公共窗口内，如果语音末端没有真实帧，模型可以结合音频掩码和文本、视觉信息完成判断；如果视觉没有人脸但存在背景运动，视觉分支仍可利用非人脸特征。由于注意力计算对无效位置进行了屏蔽，缺失窗口不会通过 softmax 获得虚假的高权重。

6.2 预测收益与计算代价

固定 baseline 的优点是小、快、可解释，但它把所有窗口和模态的作用近似压缩成静态统计；端到端视频 Transformer 虽然表达能力更强，却需要更大数据规模和更高计算成本。本文采用三路 BiGRU、掩码注意力和门控融合，是一种中等复杂度方案。其参数量主要由三路投影和 GRU 决定，时间复杂度随 50 窗口线性增长，训练和推理仍可在常规 GPU 或 CPU 环境完成。

表 6.1 模型复杂度的定性比较

方案	时间建模	缺失掩码	模态自适应	解释出口	复杂度
固定对齐 baseline	无或弱	弱	无	统计对照	低
单路 GRU 融合	有	部分	弱	隐状态	中
最终层次融合模型	三路双向	显式	显式门控	注意力加遮挡	中高
端到端视频 Transformer	时空注意力	可扩展	可扩展	需额外解释器	高

6.2.1 参数量、运算量与候选准入

为了避免“模型复杂”只停留在定性描述，本文进一步按最终 checkpoint 的结构核算可训练参数量。记隐藏维度为 $H = 128$ ，双向 GRU 每个方向的隐藏维度为 $h = H/2 = 64$ ，公共窗口数为 $K = 50$ 。对于输入维度为 d_q 的模态 q ，其投影层参数量为 $d_q H + H$ 。由于两

层双向 GRU 的每个方向在两层都接收 H 维输入，其 GRU 参数量为

$$P_{\text{GRU}} = 2L(3hH + 3h^2 + 6h), \quad L = 2. \quad (6.1)$$

式中最后一项来自每层输入偏置和隐状态偏置。按照代码中的实际结构，三路投影层共 112640 个参数，三路双向 GRU 共 446976 个参数，模态归一化共 768 个参数；时间注意力、样本级门控、融合层和双任务输出头分别为 1155、50435、131712 和 516 个参数。因此最终模型总参数量为

$$P_{\text{final}} = 112640 + 446976 + 768 + 1155 + 50435 + 131712 + 516 = 744202. \quad (6.2)$$

固定对齐 **baseline** 使用三路投影、卷积聚合、静态掩码平均池化和一层融合，在其实际隐藏维度 64 下参数量为 106372。因此最终模型约为 **baseline** 的 7.00 倍，但仍远小于引入全局时空自注意力的端到端视频模型。这里的参数增加对应明确的建模职责，而不是将同一层重复堆叠：

- (1) 双向 GRU 将 50 个窗口作为有序序列，表示情绪铺垫、转折和收束等时间依赖；
- (2) 掩码注意力只在有效窗口上归一化，阻断缺失窗口通过 **softmax** 获得虚假权重；
- (3) 样本级门控根据三路池化表示估计模态可靠性，允许同一条样本在文本、语音和视觉之间自适应分配权重；
- (4) 分类头和回归头共享融合表示但分开优化，使极性和强度不被强行压成一个标签。

从计算复杂度看，三路编码的主项可写成

$$O\left(\sum_{q \in \{t, a, v\}} K(d_q H + L H^2)\right), \quad (6.3)$$

其中 $K = 50$ 固定，注意力和门控只增加线性池化及 H 维多层感知机开销，不产生 $K \times K$ 的全局时空注意力矩阵。因此，模型处于“明显高于静态 **baseline**、但仍可在普通 GPU 或 CPU 上复核”的中等复杂度区间。复杂度审计结果见表 6.2。

表 6.2 最终模型与固定 baseline 的定量复杂度

模块或方案	参数量	相对 baseline	作用
固定对齐 baseline	106372	1.00	静态聚合参照
三路投影层	112640	–	统一模态维度
三路两层双向 GRU	446976	–	窗口序列建模
编码器归一化	768	–	稳定三路编码
掩码时间注意力	1155	–	局部证据排序
门控与融合层	182147	–	模态可靠性与交互
分类、回归输出头	516	–	双任务预测
最终层次融合模型	744202	7.00	复杂主模型

参数量本身不能证明模型有效，因此本文采用“最终模型各阶段接口一致、同一附件 2 验证划分、四项原始指标同时检查”的选择约束。由于固定 baseline 的文本特征不同，下述变化是系统级比较而非仅对架构的消融。最终模型相对固定 baseline 的改变量向量为

$$\Delta = (+0.024726, +0.013465, -0.004181, +0.005046), \quad (6.4)$$

其四个分量依次对应 Accuracy、Macro-F1、MAE 和 Pearson。由于 MAE 是越低越好，负号表示误差下降；另外三个正号表示性能提升。该向量比只报告 Accuracy 更严格：如果模型仅凭增加参数提高某一项，而损害其余指标，就不能被本文的最终选择规则接受。图 6.1 根据实际 checkpoint 分解最终模型的参数，并与固定 baseline 的 106372 个参数对照；最终模型有 744202 个可训练参数，约为 baseline 的 7 倍。图 6.2 将 MAE 的改善记为正向变化：验证集最终模型四项改善，测试集重采样候选相对 aligned baseline 的四项也改善，但它们属于不同输入版本。该图为单次实验的描述性对照，不包含显著性检验或置信区间，不能据此声称最终模型全面泛化优势。




图 6.1 模型参数量对比与构成




图 6.2 验证集最终模型与测试集重采样候选相对 aligned baseline 的定向指标差值；MAE 取反向差

从合规性角度，旧 residual fusion 和 unaligned_resampled_50 虽然在测试候选中有可比较的结果，但其训练或特征组织接口与最终专项文本重建规则不完全一致，不能直接作为统一主模型的泛化证据。因此，本文把“复杂度足够”和“超过 baseline”置于“输入接口一致”之后：只有同时满足统一文本版本、统一 aligned_50 特征、同一掩码规则、训练集归一化和验证集四指标优于 baseline 的模型，才有资格成为主模型。最终的 744202 参数 attention-gate 模型满足这五项条件，测试候选不改变最终选择。

6.3 误差来源与可复现性

6.3.1 跨场景适用条件

本文仍有四类限制。第一，文本词级定位没有人工 gold timestamp，当前结果只能称为弱或半强对齐；第二，附件 3 和附件 4 无标签，无法计算真正的专项泛化指标；第三，解

释方法是后验遮挡，不应夸大因果证明；第四，附件 2 test 尚未形成最终 attention-gate 模型的可审计预测文件，现有测试候选来自不同输入版本，说明数据划分与接口一致性仍会影响结果。

针对上述限制，可从四个方向改进：

- (1) 建立约 20 条样本的人工词级起止时间标注，计算边界 MAE、容差命中率和区间 IoU；
- (2) 在统一接口下进行多随机种子重复实验，报告均值、标准差和置信区间；
- (3) 将门控权重与遮挡下降联合建模，使用可学习的可靠性估计处理模态质量变化；
- (4) 在更大数据集上比较轻量化 TCN、Transformer encoder 和跨模态交互层，并以同一特征 manifest 保证公平。

6.3.2 可复现实验与证据留存

本项目将报告、checkpoint、输入 manifest、输出 CSV 和图表脚本分别保存。最终模型的配置为隐藏维度 128、层数 2、Dropout 0.15、双向 GRU、回归损失权重 0.5、seed 42。特征编码使用 distilbert-base-uncased 固定 revision 12040accade4e8a0f71eabdb258fecc2e7e948be；运行环境记录 PyTorch 1.8.0、Transformers 4.29.2、PyAV 12.3.0、NumPy 1.24.3。所有附件 3 与附件 4 预测均明确标注无标签，不从中计算监督指标。

6.3.3 最终模型准入条件与风险边界

为了把“合规、复杂度和超过 baseline”从口号转化为可执行的筛选规则，本文对最终模型设置五道准入门槛。第一道是输入门槛：训练、验证和专项推理必须共享同一份 feature manifest，文本必须使用题目提供的 text_bert token、固定 DistilBERT revision 和最后四层均值规则，音频与视觉必须使用同一版 aligned_50。第二道是结构门槛：缺失窗口必须同时满足数值置零和 mask 为 0，且注意力归一化不能把无效窗口重新纳入分母。第三道是训练门槛：均值、方差和阈值只由训练集估计，模型轮次只由验证集选择，test、附件 3 和附件 4 不能反向调参。第四道是性能门槛：在附件 2 验证集上同时检查 Accuracy、Macro-F1、MAE 和 Pearson，前三项分别按高、高、低方向判断，不能用一个综合分数掩盖单项退化。第五道是解释门槛：模型需要输出模态贡献、窗口注意力、遮挡变化和证据文件；若没有可追溯字段，即使预测分数较高，也不能作为问题 3 的主模型。

上述门槛形成一个有序决策，而不是事后挑选结果。设候选模型为 r ，用指示量表示其是否通过第 j 道门槛，则准入函数可写为

$$\text{Admit}(r) = \prod_{j=1}^5 \mathbb{I}\{G_j(r) = 1\}. \quad (6.5)$$

只有 $\text{Admit}(r) = 1$ 的候选才进入最终性能排序；在多个候选均通过时，再使用问题二建模阶段定义的 $S = F1_{macro} - 0.1 \times MAE$ 进行排序。该规则避免出现“旧模型指标略高，

所以忽略接口不一致”的倒置逻辑，也避免为了满足复杂度要求而盲目增加网络层数。最终 attention-gate 模型的通过证据汇总于表 6.3。

表 6.3 最终主模型的五道准入门槛

门槛	通过证据	不通过时的处理
输入接口	text_bert、固定 revision、aligned_50 和 manifest 一致	新建特征版本，不复用 checkpoint
缺失结构	缺失位置置零，mask 为 0，注意力屏蔽无效窗	重新执行掩码审计
数据使用	归一化只看训练集，选模只看验证集	删除泄露结果并重新训练
四指标性能	验证集 Accuracy、Macro-F1、Pearson 上升且 MAE 下降	不作为最终主模型
解释输出	模态贡献、50 窗遮挡、证据 CSV 和关键帧均可追溯	只能作为预测候选

需要特别区分“准入通过”和“外部泛化已被证明”。本模型在当前附件 2 验证集上满足五道门槛，并且四项指标均超过固定对齐 baseline；这支持完整系统的模型选择结论，但两者文本特征并未匹配，不能宣称网络结构的单因素优势，也不足以推出所有新样本上都全面优于 baseline。附件 2 test 的 Macro-F1 和 MAE 波动、文本缺少人工 gold timestamp、附件 3 和附件 4 缺少监督标签，均属于必须保留的风险边界。因而，本文把最终模型表述为“自身输入接口合规、在附件 2 验证集超过指定简单 baseline 的中等复杂度主模型”，而不把它夸大为无条件最优模型。

7 结论与展望

本文针对复杂场景下三模态情感识别问题，建立了从数据审计、统一时间轴、层次融合到证据追踪的一体化数学建模方案。主要结论如下：

- 结论 1. 50 窗公共时间轴是多模态建模的基础。通过半开区间与重叠时长加权，文本、语音和视觉可以映射到统一索引；通过显式 mask 可以区分真实零值与缺失。100 条样本的时间结构和掩码一致性均通过审计，音视频覆盖率达到 99.00% 和 99.80%。
- 结论 2. 统一输入接口是严格比较的前提。最终模型固定使用 text_bert+aligned_50，文本编码版本、特征规则、掩码和归一化统计量在训练、验证和专项推理中保持一致；旧 residual 模型不再作为最终结果。
- 结论 3. 三路双向 GRU、模态内时间注意力和样本级模态门控构成了适度复杂的层次融合模型。它不只是增加参数，而是分别对应时间依赖、局部证据和模态可靠性三个问题。
- 结论 4. 在附件 2 验证集上，最终模型四项报告指标均超过固定对齐 baseline: Accuracy **0.637363**、Macro-F1 **0.601580**、MAE **0.612262**、Pearson **0.629628**。
- 结论 5. 通过注意力最高窗与随机窗的反事实遮挡比较，Top-Random 为 **0.009704**，说明模型可为预测提供局部证据；但该结果仍属于模型行为解释，不能替代人工因果验证。

总体而言，本文最终方案在合规性、模型复杂度、预测性能和可解释性之间取得了平衡，适合作为附件 2 监督预测与附件 4 专项证据生成的统一主模型。后续若获得人工词级时间戳和更大规模标注数据，可进一步从对齐金标准和跨域泛化两方面提升模型可信度。

参考文献

- [1] Poria S, Cambria E, Bajpai R, et al., A review of affective computing: From unimodal analysis to multimodal fusion, *Information Fusion*, 37:98-125, 2017.
- [2] Baltrusaitis T, Ahuja C, Morency L P, Multimodal Machine Learning: A Survey and Taxonomy, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2):423-443, 2019.
- [3] 张亚洲, 戎璐, 宋大为, 等, 多模态情感分析研究综述, *模式识别与人工智能*, 33(5): 426-438, 2020.
- [4] 段宗涛, 黄俊臣, 朱晓乐, 视频多模态情感分析关键技术研究综述, *计算机科学与探索*, 19(3):539-558, 2025.
- [5] Tsai Y H H, Bai S, Liang P P, et al., MULT: A Multimodal Transformer for Unaligned Multimodal Language Sequences, *Proceedings of ACL*, 6558-6569, 2019.
- [6] 周志华, 机器学习, 北京: 清华大学出版社, 2016.
- [7] 李航, 统计学习方法 (第 2 版), 北京: 清华大学出版社, 2019.
- [8] Mikolov T, Sutskever I, Chen K, et al., Distributed Representations of Words and Phrases and their Compositionality, *Advances in Neural Information Processing Systems*, 26, 2013.
- [9] Devlin J, Chang M W, Lee K, et al., BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, *Proceedings of NAACL-HLT*, 4171-4186, 2019.
- [10] 宗成庆, 统计自然语言处理 (第 2 版), 北京: 清华大学出版社, 2013.
- [11] Sanh V, Debut L, Chaumond J, et al., DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter, *arXiv preprint arXiv:1910.01108*, 2019.
- [12] Graves A, Fernandez S, Gomez F, et al., Connectionist Temporal Classification: Labelling Unsegmented Sequence Data with Recurrent Neural Networks, *Proceedings of the 23rd International Conference on Machine Learning*, 369-376, 2006.
- [13] Davis S, Mermelstein P, Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences, *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 28(4):357-366, 1980.
- [14] Cho K, van Merriënboer B, Gulcehre C, et al., Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation, *Proceedings of EMNLP*:1724-1734, 2014.
- [15] Bahdanau D, Cho K, Bengio Y, Neural Machine Translation by Jointly Learning to Align and Translate, *International Conference on Learning Representations*, 2015.
- [16] Goodfellow I, Bengio Y, Courville A, *Deep Learning*, MIT Press, 2016.

附录

A 数据字段与交付文件

A.1 输入特征、掩码与标签字段

表 A.1 最终数据字典

字段	形状或类型	说明
id	字符串	样本唯一标识，跨附件保持可追溯
text_bert	($N, 3, 50$)	token ID、attention mask 等文本输入
text	($N, 50, 768$)	固定 DistilBERT 规则生成的窗口文本表示
audio	($N, 50, 74$)	语音窗口级统计特征
vision	($N, 50, 35$)	视觉窗口级统计特征
classification_labels	($N, $)	Negative、Neutral、Positive 编码为 0、1、2
regression_labels	($N, $)	连续情感强度标签
aligned_50.pkl	pickle	附件 2 统一时间窗特征
aligned_text_bert_features.pkl	pickle	统一文本接口派生特征
fusion_best.pt	checkpoint	严格统一接口的基础融合候选
q3_explainable_best.pt	checkpoint	最终统一编码复杂主模型

A.2 预测、解释与论文交付文件

表 A.2 论文与模型输出文件

文件	用途
三个问题综合审查与最终结果报告.md	总体路线、风险与指标口径
问题 1_最终报告_特征提取与时序对齐.md	公共时间轴和特征审计
q2_baseline/问题 2_附件 3 测试报告.md	附件 3 统一接口专项推理
q3_explainability/	最终模型验证指标
q3_aligned_text_bert_final/validation.json	
attachment4/q3_predictions.csv	附件 4 预测与模态贡献
attachment4/q3_explanations.csv	附件 4 证据排名与遮挡变化
video_keyframe_manifest.csv	视觉关键帧时间和哈希清单

文件	用途
make_figures.py	本论文全部图表生成脚本

B 核验规则与关键算法

B.1 公共时间轴核验算法

alignment-check.py

```

for sample in samples:
    T = sample.media_duration
    windows = [(k*T/50, (k+1)*T/50) for k in range(50)]
    assert abs(windows[0][0]) < 1e-8
    assert all(windows[k][1] <= windows[k+1][0] + 1e-8
               for k in range(49))
    assert abs(windows[-1][1] - T) < 1e-6
    for modality in modalities:
        values, mask = aggregate_by_overlap(sample, windows, modality)
        assert values.shape[0] == 50
        assert np.all(np.isfinite(values[mask]))
        assert np.all(values[~mask] == 0)

```

B.2 掩码门控模型前向算法

model-forward.py

```

for modality in (text, audio, vision):
    encoded = projection[modality](values[modality])
    encoded = encoded * mask[modality].unsqueeze(-1)
    temporal = bigru[modality](encoded)
    tokens = layer_norm(encoded + dropout(temporal))
    scores = time_score[modality](tokens)
    scores = scores.masked_fill(~mask[modality], -1e4)
    alpha = softmax(scores, dim=1)
    pooled.append((tokens * alpha.unsqueeze(-1)).sum(dim=1))
stacked = torch.stack(pooled, dim=1)
beta = softmax(gate(stacked.flatten(1)), dim=-1)
fused = fusion((stacked * beta.unsqueeze(-1)).flatten(1))
class_logits = classifier(fused)
strength = regressor(fused).squeeze(-1)

```

B.3 模态与时间窗证据生成算法

explain.py

```
base_logits, base_strength, beta, attention = model(x, mask)
target = base_logits.argmax(dim=-1)
base_prob = softmax(base_logits, dim=-1)[target]
for modality in modalities:
    for window in range(50):
        x_masked, mask_masked = hide_window(x, mask, modality, window)
        changed_logits, changed_strength, _, _ = model(x_masked,
            mask_masked)
        drop = base_prob - softmax(changed_logits, dim=-1)[target]
        evidence = attention[modality][window] * beta[modality] * max(
            drop, 0)
        save(modality, window, evidence, drop, changed_strength)
```

B.4 结果一致性审计规则

表 B.1 关键审计规则与通过标准

类别	检查项	通过标准
时间结构	窗口首点、连续性、终点、正时长	四项比例均为 100%
词段结构	越界、正时长、单调、重叠	越界、非正时长、非单调、重叠均为 0
掩码结构	缺失窗口与零值一致性	有效位置有限，缺失位置置零且 mask 为 0
数据泄露	归一化统计量和模型选择	只使用训练集统计量与验证集指标
专项测试	附件 3 或 4 监督标签使用	无标签，不计算 Accuracy、F1、MAE、Pearson

C 模型配置与训练记录

表 C.1 最终模型超参数

参数	取值
文本编码器	distilbert-base-uncased
文本 revision	12040accade4e8a0f71eabdb258fecc2e7e948be
公共时间窗	50
隐藏维度	128
GRU 层数	2
双向	True
Dropout	0.15
Batch size	64
学习率	2×10^{-4}
回归损失权重	0.5
随机种子	42
解释验证样本	128
每条附件 4 证据	6

C.1 候选模型验证记录

表 C.2 主要候选模型的验证记录

模型	Accuracy	Macro-F1	MAE	Pearson	选择结论
Fixed aligned baseline	0.612637	0.588115	0.616443	0.624582	参考
Length-aware baseline	0.614011	0.595798	0.614132	0.620838	对比
Label-free SSL	0.608516	0.578294	0.667391	0.573212	放弃
Bidirectional SSL	0.618132	0.598285	0.621818	0.588408	对比
Old residual fusion	0.622253	0.610330	0.623941	0.601396	历史
Final attention-gate	0.637363	0.601580	0.612262	0.629628	最终

C.2 软件环境与版本

软件或硬件	版本或说明
Python	D:/Anaconda3/envs/pytorch/python.exe
PyTorch	1.8.0
Transformers	4.29.2
NumPy	1.24.3
PyAV	12.3.0
文本模型	distilbert-base-uncased 固定 revision
输出格式	CSV、JSON、PNG、PDF、checkpoint

D 附件 4 预测与证据记录

表 D.1 附件 4 前 20 条样本的预测摘要

ID	类别	强度	主模态	文本贡献	语音贡献	视觉贡献
01	Neutral	0.255	text	0.726	0.110	0.164
02	Negative	0.041	text	0.461	0.409	0.130
03	Neutral	-0.491	text	0.658	0.125	0.217
04	Negative	-0.594	text	0.611	0.115	0.274
05	Positive	1.022	text	0.709	0.109	0.182
06	Positive	0.052	text	0.550	0.298	0.152
07	Positive	0.666	text	0.681	0.226	0.093
08	Positive	0.882	text	0.530	0.288	0.182
09	Negative	-2.108	text	0.764	0.095	0.141
10	Negative	-1.948	text	0.854	0.046	0.100
11	Negative	-1.998	text	0.750	0.195	0.055
12	Negative	-0.427	text	0.454	0.376	0.170
13	Neutral	0.287	text	0.519	0.316	0.165
14	Positive	0.843	text	0.708	0.115	0.177
15	Positive	0.912	text	0.686	0.084	0.230

ID	类别	强度	主模态	文本贡献	语音贡献	视觉贡献
16	Negative	-1.994	text	0.689	0.190	0.121
17	Positive	1.218	text	0.688	0.208	0.104
18	Negative	-0.534	text	0.763	0.109	0.129
19	Positive	0.177	text	0.756	0.110	0.134
20	Positive	1.112	text	0.693	0.096	0.211

D.1 局部证据字段释义

字段	含义
rank	当前样本证据排序，1 为最高
modality	text、audio 或 vision
window_index	0-49 公共时间窗索引
attention_score	模态内时间注意力
modality_contribution	样本级门控或消融贡献
occlusion_drop	屏蔽该窗口后的目标置信度下降
evidence_score	式 (5.4) 的综合证据分数
regression_change	屏蔽后的强度预测变化
frame_path	与视觉窗口对应的实际关键帧路径

E 复现流程与提交前核对

E.1 特征构建、训练与验证命令

```
$q1 = "E题复杂场景下多模态情感识别的数学建模与算法设计\question1_alignment"
& powershell -ExecutionPolicy Bypass -File "$q1\run_alignment.ps1" `
-DataRoot "E题复杂场景下多模态情感识别的数学建模与算法设计\E题数据\E题数据" `
-OutputDir "$q1\output_speech_aware"

$py = "D:\Anaconda3\envs\pytorch\python.exe"
$q3 = "q3_explainability"
$final = "$q3\q3_aligned_text_bert_final"
$checkpoint = "$final\q3_explainable_best.pt"
```

```
$explanation = "$final\\explanation_validation.json"
$aligned = "emotion-transfer-pilot\\aligned_50.pkl"
$data_dir = "emotion-transfer-pilot"
$derived = "$data_dir\\aligned_text_bert_features.pkl"
$manifest = "q2_baseline\\aligned_text_bert_manifest.json"
& $py q2_baseline\\run_aligned_text_bert.py prepare `
    --aligned-data $aligned `
    --derived-data $derived `
    --manifest $manifest
& $py q3_explainability\\q3_pipeline.py validate `
    --data $derived `
    --checkpoint $checkpoint `
    --output $explanation `
    --device cpu
```

E.2 交付文件一致性核对

1. 检查 aligned_text_bert_manifest.json 的输入和派生文件 SHA-256;
2. 检查训练、验证和附件 3 的文本接口均为固定 revision;
3. 检查所有缺失窗口同时满足特征为零、mask 为 0;
4. 检查模型 checkpoint 中的 config 与论文超参数表一致;
5. 检查附件 3 和附件 4 没有被用于监督指标或模型选择;
6. 检查最终 PDF 正文页数超过 30 页，并检查图、表、公式和参考文献无越界。

E.3 结果解释与适用范围声明

本文的“超过 baseline”特指相同附件 2 验证划分上，四项指标均优于原始对齐特征的固定 baseline。最终模型的文本接口为 text_bert+aligned_50，两个比较对象的文本特征不同，因此不得把系统级增益归因于纯架构消融。附件 2 test 只作独立复核，附件 3 和附件 4 无监督标签，不计算监督指标。旧 residual 模型的历史结果不作为最终合规主模型。本声明用于避免混写不同接口、划分和标签条件下的结果。